



SmartAssign

Automatisierte Dokumentenzuordnung zu Transportaufträgen mittels intelligenter
Belegerkennung

Projektbericht im IT-Studienprojekt

Sommersemester 2026

vorgelegt von

Fajer Ahmed

400855

Wirtschaftsinformatik

Ali Kemaliddin Artun

400010

Wirtschaftsinformatik

Matteo Geiger

405375

Wirtschaftsinformatik

Tim Wiedenroth

4022040

Wirtschaftsinformatik

Hildesheim, den **28.08.2026**

Inhaltsverzeichnis

Abbildungsverzeichnis	iii
Tabellenverzeichnis	iii
Abkürzungsverzeichnis	iii
1 Einleitung	1
1.1 Problemstellung und Motivation	1
1.2 Zielsetzung der Arbeit	2
1.3 Aufbau der Arbeit	3
2 Ausgangssituation	3
2.1 Unternehmensprozess	3
2.2 Problemanalyse	6
2.3 Anforderungen an den Prototyp	7
3 Literaturüberblick	8
3.1 Dokumentenverarbeitung	9
3.2 Informationsextraktion	11
3.3 Matching- und Zuordnungsverfahren	13
3.4 Projekteinordnung	15
4 Konzeption des Systems	16
4.1 Soll Prozessmodellierung	16
4.2 Systemarchitektur	19
4.3 Datenmodell	21
5 Umsetzung des Prototyps	24
5.1 Verwendete Technologien	24
5.2 Textextraktion und OCR	26
5.3 Matching Verfahren	28
5.3.1 Kandidatensuche	28
5.3.2 Kandidatenbewertung	29
5.4 Benutzeroberfläche	30
6 Evaluation	34
6.1 Untersuchungsdesign und Testdaten	35
6.2 Erfüllung der Anforderung	36
6.3 Grenzen und Übertragbarkeit	37
7 Fazit und Ausblick	38
7.1 Rückblick	38
7.2 Bewertung der Evaluation	39
7.3 Offene Fragen und Übertragbarkeit	40
Literaturverzeichnis	42

Abbildungsverzeichnis

Abbildung 1: Ist-Prozess der Zuordnung nachgelagerter Fremdbelege bei Spedifix (Quelle: eigene Darstellung).....	5
Abbildung 2: Soll-Prozess der systemgestützten Belegzuordnung (Quelle: eigene Darstellung)	18
Abbildung 3: Übersicht von SmartAssign (Quelle: eigene Darstellung)	31
Abbildung 4: Zuordnungsübersicht in SmartAssign (Quelle: eigene Darstellung)	32
Abbildung 5: Auftragsübersicht in SmartAssign (Quelle: eigene Darstellung).....	33
Abbildung 6: Auswertungsseite in SmartAssign (Quelle: eigene Darstellung)	33
Abbildung 7: Einstellungsseite von SmartAssign (Quelle: eigene Darstellung)	34

Tabellenverzeichnis

Tabelle 1: Anforderungen an den Prototyp (Quelle: eigene Darstellung)	8
Tabelle 2: Objekt des Datenmodells (Quelle: eigene Darstellung).....	22
Tabelle 3: Eingesetzte Mittel (Quelle: eigene Darstellung)	25
Tabelle 4: Gewichtung der Merkmale für die Kandidatenbewertung.....	29
Tabelle 5: Textdateien (Quelle: eigene Darstellung)	35
Tabelle 6: Bewertung nach Bereichen (Quelle: eigene Darstellung)	36

Abkürzungsverzeichnis

deu	Sprachpaket Deutsch
LLM	Large Language Model
NER	Named Entity Recognition
OCR	Optical Character Recognition
XOR	exklusives oder

1 Einleitung

Im Einleitungskapitel werden drei Aspekte behandelt. Zunächst werden Problemstellung und Motivation dargestellt. Anschließend wird das Ziel der Arbeit benannt. Abschließend wird der Aufbau der Ausarbeitung erläutert.

1.1 Problemstellung und Motivation

Ein Beleg gehört fachlich zu einem Auftrag, liegt aber zunächst nur als Datei oder als Papier vor. Bei der Annahme im Büro entstehen Stammdaten und oft schon Frachtpapiere. Die werden im System erzeugt und können dort archiviert werden. Der Auftrag ist damit angelegt, die Erfassungsnummer vergeben und die ersten Unterlagen hängen bereits am richtigen Datensatz. Der Durchlauf ist an dieser Stelle nicht zu Ende. Später kommen weitere Unterlagen hinzu. Zusätzlich zählen dazu Nachweise über den Wareneingang, Schadensmeldungen, Eingangsrechnungen, gelegentlich auch andere Fremdbelege, die ein Absender oder ein Empfänger nachreicht, sind auch mögliche Unterlagen. Sie erreichen das Unternehmen als PDF, JPEG oder PNG, als Scan, als E-Mail-Anhang oder als Papier (vgl. Fiebach 2026, S. 1).

Papier und digitale Dateien sind dabei nicht dasselbe Problem, führen aber auf dieselbe offene Stelle. Ein Papierbeleg muss erst digitalisiert werden, sonst gibt es nichts zu vergleichen und nichts abzulegen. Ein bereits digitales PDF kann Text als Zeichen enthalten oder nur ein Bild der Seite. Ein Foto vom Beleg ist von vornherein ein Bild. In allen drei Fällen ist der Beleg erst dann im Sinne des Auftragsdurchlaufs verarbeitet, wenn er einem bestehenden Auftrag gegenübersteht. Ohne diese Gegenüberstellung bleibt er eine Datei in einem Ordner oder ein Papier neben dem Bildschirm.

Würde auf jedem dieser Belege dieselbe Erfassungsnummer stehen wie im Auftragskopf, und zwar maschinenlesbar und unter einer Bezeichnung, die das Büro erwartet, wäre die Verknüpfung ein Ablesen. Genau das ist häufig nicht der Fall. Die Nummer fehlt ganz, sie steht hinter einer anderen Bezeichnung als im eigenen System, etwa Auftragsnummer, Sendungs-Nr., Referenz, oder ErfNr, oder sie sind auf einem Scan nur als Bild vorhanden. Die Sachbearbeitung öffnet den Beleg, sucht im System, vergleicht Absender, Empfänger, Datum oder die Auftragsnummer und setzt die Zuordnung manuell, bevor die Datei ins Archiv kommt.

Dieser Schritt ist kein Einzelfall. Nach Angaben des Praxispartners können auf einen Auftrag zehn bis zwanzig solcher Zusatzdokumente anfallen (vgl. Fiebach 2026, S. 1). Die manuelle Zuordnung wiederholt sich deshalb je Auftrag und hängt von der jeweiligen Person ab. „Am Wochenende übernimmt teilweise die Geschäftsführung diese Aufgabe (vgl. Fiebach 2026, S. 1)“. Haben zwei Sendungen ähnliche Absender oder Empfänger, kann der falsche Auftrag gewählt werden. Ohne Verknüpfung bleibt die Datei im Sammelordner. Der Beleg ist dann vorhanden, hängt aber an keinem Auftrag.

Texterkennung, Extraktion einzelner Angaben und der Abgleich von Datensätzen sind in der Literatur beschrieben. PDF-Dateien mit eingebettetem Text lassen sich als Text lesen,

gerasterte Seiten über eine Zeichenerkennung, einzelne Felder über Muster oder über lernende Verfahren. Datensätze lassen sich exakt oder teilweise einander zuordnen. Gebraucht wird keine weitere allgemeine Fertiglösung, sondern eine Hilfe, die in genau diesem Prozess greift. Es sollen Vorschläge gemacht werden, Begründungen herangeführt werden und nicht vor der Bestätigung gespeichert werden.

Der eigene Ansatz setzt am bestehenden Ist-Prozess an, mit den Formaten der Aufgabenstellung und mit der Vorgabe, dass der Mitarbeiter die letzte Entscheidung behält. Das Problem ist die Übertragung von bekannten Verfahren auf diesen Zuschnitt und nicht das Fehlen jeder Literatur zum Thema Dokument und Datensatz.

1.2 Zielsetzung der Arbeit

Ziel der Arbeit ist ein Prototyp, der die manuelle Zuordnung auf Prüfung und Bestätigung verkürzt. Damit ist nicht gemeint, den gesamten Auftragsdurchlauf neu zu entwickeln. Auftragserfassung, Druck der Frachtpapiere und die automatische Archivierung bleiben, wie sie sind (vgl. Fiebach 2026, S. 1). Grundsätzlich geht es um den Weg vom eingegangenen Fremdbeleg bis zu einer bestätigten Verknüpfung.

Dieser Weg soll im Prototyp durchlaufen werden können. Eingehende Dateien werden übernommen, mindestens PDF, JPEG und PNG, wie es die Aufgabenstellung verlangt. Text wird zuerst aus der Datei gelesen. Nur wenn das nicht reicht, folgt eine Zeichenerkennung. Gesucht wird die Auftragsnummer hinter festgelegten Bezeichnungen, nicht die erste Zahl im Beleg. Eine Rechnungsnummer oder eine Postleitzahl darf den Vorschlag nicht tragen, nur weil sie auffällig ist. Danach soll höchstens ein Auftrag vorgeschlagen und begründet werden. Geschrieben wird die Verknüpfung erst nach der Bestätigung. In der Oberfläche heißt der Prototyp SmartAssign.

Zum Ziel gehört die Reduzierung des manuellen Aufwands ebenso wie die korrekte Zuordnung. Zur Abgrenzung gilt: Handschrift wird nicht erkannt, die Spedifix-Umgebung wird nicht angebunden, in das bestehende Belegarchiv wird nicht geschrieben, ein lernendes Matching wird nicht trainiert und die Entscheidung bleibt bei dem Mitarbeiter.

Erreicht ist das Ziel, wenn sich dieses Verhalten am Studienprototyp nachvollziehen lässt: Formate, Textweg, Label, Vorschlag, Begründung und Bestätigung. Nicht erreicht ist es, wenn dieselbe Verkürzung im laufenden Belegarchiv von Spedifix nachgewiesen wäre. Dafür fehlen Betriebsbelege und die produktive Anbindung. Eine Trefferquote gegen den Betrieb wird nicht behauptet.

Die Zielsetzung ist damit bewusst schmaler als der Wunsch, „den Prozess zu automatisieren“. Automatisiert werden Lesen, Suche und Vorschlag. Nicht automatisiert wird die Freigabe. Diese Trennung ist in den Anforderungen festgehalten.

1.3 Aufbau der Arbeit

Die vorliegende Arbeit ist in sieben Kapitel gegliedert, die aufeinander aufbauen und den Weg von der Problemstellung bis zur abschließenden Bewertung der entwickelten Lösung darstellen. Kapitel 2 beschreibt zunächst die Ausgangssituation bei Spedifix und konkretisiert die Problemstellung. Dabei werden bestehende Unternehmensprozess, die damit verbundenen Herausforderungen sowie die Anforderungen an die zu entwickelnde Lösung dargestellt. Anschließend verschafft Kapitel 3 einen Überblick über bestehende Forschung und schafft damit die wissenschaftliche Grundlage für die weitere Entwicklung. Hier werden die Dokumentenverarbeitung, Informationsextraktion sowie verschiedene Matching Verfahren beleuchtet, bevor ein konkreter Plan für die Umsetzung entwickelt werden kann. Auf Grundlage dieser Erkenntnisse wird in Kapitel 4 die Konzeption des Systems illustriert. Neben der Soll Prozessmodellierung werden dabei die Systemarchitektur und das zugrunde liegende Datenmodell beschrieben. Die daran anschließende technische Umsetzung der Konzeption wird in Kapitel 5 erläutert. Hierzu gehören die eingesetzten Technologien, Textextraktion, OCR, das entwickelte Matching Verfahren sowie die Umsetzung der Benutzeroberfläche. Die entwickelte Anwendung wird dabei in Kapitel 6 evaluiert. Hierzu werden zunächst das Untersuchungsdesign und die verwendeten Testdaten beschrieben. Abschließend werden die Grenzen der Untersuchung sowie Übertragbarkeit der Ergebnisse diskutiert. Zum Schluss fasst Kapitel 7 die zentralen Ergebnisse der Arbeit in Hinblick auf die ursprüngliche Problemstellung und Zielsetzung zusammen. Darüber hinaus werden offene Fragen und mögliche Weiterentwicklungen aufgezeigt.

2 Ausgangssituation

Kapitel 2 behandelt drei Aspekte. Zunächst wird die Ausgangssituation bzw. die Problemstellung beschrieben, die sich bei Spedifix im Umgang mit nachgelagerten Belegen stellt. Anschließend werden die Schwächen der bisherigen, weitgehend manuellen Zuordnung herausgearbeitet. Daraus werden die Anforderungen abgeleitet, an denen der Prototyp in Kapitel 6 gemessen wird. Der Ist-Prozess wird als ereignisgesteuerte Prozesskette dargestellt. Dabei wird die Modellierungssprache selbst nicht erläutert.

2.1 Unternehmensprozess

Im aktuellen Unternehmensprozess von Spedifix wird die Bearbeitung und Zuordnung von Fremddokumenten beschrieben, die sich auf bestimmte vorhandene Aufträge beziehen. Häufig beinhalten diese Dokumente keine eindeutige Auftragsnummer, weshalb ein zusätzlicher Aufwand entsteht. Denn die jeweiligen Dokumente müssen einem vorhandenen Auftrag zugeordnet werden (vgl. Fiebach 2026, S. 1).

Der Prozess beginnt mit dem Eintreffen eines Fremddokuments. Dabei kann das Dokument entweder als digitaler Beleg oder als Papierbeleg vorliegen. In der Ausgangssituation von Spedifix wird beschrieben, dass im Laufe eines Auftrags unterschiedliche Dokumente, beispielsweise Schadensmeldungen, Eingangsrechnungen oder weitere Dokumente, eintreffen

können. Diese Dokumente können sowohl digital als auch in Papierform vorliegen. Zudem wird angemerkt, dass diese Dokumente meistens nicht die zugehörige Auftragsnummer enthalten (vgl. Fiebach 2026, S. 1).

Nach dem Eintreffen des Fremddokuments erfolgt zunächst eine Unterscheidung hinsichtlich der vorliegenden Dokumentenform. Sollte es sich um einen Papierbeleg handeln, muss dieser dann gescannt werden. In der Ist-Modellierung wird dieser Schritt durch die Funktion „Scanne eingetroffenes Dokument als Papierbeleg“ dargestellt. Nach dem Scan liegt das Dokument anschließend digital vor.

Tritt der Fall ein, dass das Dokument bereits in digitaler Form vorliegt, wird der Scanvorgang übersprungen. Stattdessen wird der digitale Beleg in einem Ordner abgelegt. Die Ist-Modellierung stellt diesen Schritt durch die Funktion „Lege digitalen Beleg in einem Ordner ab“ dar. Anschließend liegt der digitale Beleg im Ordner vor.

Nachdem das Dokument digital vorliegt, wird nach der Auftragsnummer geprüft. Es wird geprüft, ob beim Dokument eine Auftragsnummer vorhanden ist. Die Ist-Modellierung bildet diesen Schritt mit der Funktion „Prüfe nach Auftragsnummer“ ab. Anschließend wird über einen XOR-Konnektor zwischen zwei möglichen Ereignissen unterschieden. Die Auftragsnummer ist vorhanden oder die Auftragsnummer ist nicht vorhanden. In beiden Fällen findet eine manuelle Zuordnung statt. Als Ergebnis wird das Dokument manuell einem Auftrag zugeordnet.

Die manuelle Zuordnung wird aktuell von einem Mitarbeiter durchgeführt. In der Ausgangssituation von Spedifix wird beschrieben, dass eine Mitarbeiterin die in Papierform vorliegenden Dokumente zunächst einscannet beziehungsweise digitale Belege in einem Ordner ablegt. Anschließend werden die Dokumente in Spedifix angezeigt und manuell einem Auftrag zugeordnet. Nach der Zuordnung wird das Dokument im digitalen Belegarchiv abgelegt (vgl. Fiebach 2026, S. 1).

Zum Abschluss des Prozesses werden die vorgenommenen Bearbeitungsschritte gespeichert. Die Modellierung stellt diesen Abschluss durch die Funktion „Speichere alles ab“ und das anschließende Ereignis „Alles ist abgespeichert“ dar. Damit ist der Prozess der Dokumentenverarbeitung abgeschlossen. Der beschriebene Ablauf ist in Abbildung 1 als ereignisgesteuerte Prozesskette dargestellt.




Abbildung 1: Ist-Prozess der Zuordnung nachgelagerter Fremdbelege bei Spedifix (Quelle: eigene Darstellung)

Zusammenfassend lässt sich feststellen, dass der aktuelle Prozess mehrere manuelle Arbeitsschritte beinhaltet. Insbesondere die Verarbeitung von Papierbelegen, die Prüfung auf eine vorhandene Auftragsnummer sowie die manuelle Zuordnung der Dokumente sind Bestandteile des bestehenden Ablaufs. Die ursprüngliche Prozessbeschreibung von Spedifix verdeutlicht zudem, dass pro Auftrag teilweise zehn bis zwanzig Dokumente anfallen können (vgl. Fiebach 2026, S. 1). Dadurch kann sich der manuelle Aufwand zum Bearbeiten entsprechend erhöhen.

Der dargestellte Ist-Prozess bildet damit die Grundlage für die Problemanalyse. Im nächsten Abschnitt wird daher untersucht, welche Probleme sich aus dem bestehenden Ablauf ergeben.

2.2 Problemanalyse

Die Betrachtung des Ist-Prozesses zeigt, dass die aktuelle Bearbeitung und Zuordnung von Fremddokumenten bei Spedifix in mehreren manuellen Schritten erfolgt. Das Problem besteht dabei insbesondere darin, dass die eingehenden Dokumente häufig keine Auftragsnummer enthalten. Dadurch kann das Dokument nicht ohne weitere Prüfung eindeutig einem bestehenden Auftrag zugeordnet werden.

Das Fehlen der Auftragsnummer auf den Dokumenten ist eine Herausforderung. Denn für die Mitarbeiter bedeutet dies, dass die manuelle Zuordnung nicht nur anhand einer vorhandenen Auftragsnummer erfolgen kann. Stattdessen muss anhand der im Dokument vorhandenen Informationen ermittelt werden, auf welchen Auftrag sich das Dokument bezieht. Dieser zusätzliche Schritt stellt ein weiteres Problem dar. Bei einer größeren Anzahl von Dokumenten wiederholt sich dieser Aufwand entsprechend oft.

Ein weiterer Problembereich besteht im hohen Anteil manueller Tätigkeiten innerhalb des Prozesses. Papierdokumente müssen zunächst eingescannt werden, während digitale Dokumente in einem Ordner abgelegt werden. Anschließend erfolgt die Prüfung auf eine Auftragsnummer und dann die manuelle Zuordnung zum entsprechenden Auftrag. Die Ist-Modellierung zeigt damit mehrere Schritte, die nicht systemgestützt durchgeführt werden.

Besonders relevant wird dieser manuelle Aufwand durch die Anzahl der Dokumente. Nach Angaben von Spedifix können sich auf einen Auftrag teilweise zehn bis zwanzig unterschiedliche Dokumente beziehen (vgl. Fiebach 2026, S. 1). Bei einer solchen Menge muss die manuelle Zuordnung entsprechend häufig durchgeführt werden.

Da die manuelle Zuordnung der Dokumente durch einen Mitarbeiter erfolgen muss, ist die Bearbeitung abhängig von diesem Mitarbeiter. Laut Ausgangssituation übernimmt derzeit ein Mitarbeiter oder teilweise auch der Chef am Wochenende diese Tätigkeit (vgl. Fiebach 2026, S. 1). Dadurch entsteht eine Abhängigkeit vom jeweils zuständigen Mitarbeiter. Die Bearbeitung kann erst erfolgen, wenn die entsprechende Person die Dokumente prüft und die Zuordnung vornimmt. Eine konkrete Bearbeitungszeit oder eine Verzögerung wird in der Ausgangssituation nicht angegeben. Daher lässt sich auf Grundlage der vorliegenden Informationen keine konkrete Aussage darüber treffen, wie viel Zeit durch eine systemgestützte Zuordnung eingespart werden könnte.

Ein weiteres Problem kann das falsche Zuordnen durch den Mitarbeiter darstellen. Da die Zuordnung nicht immer anhand eines eindeutigen Merkmals erfolgen kann, besteht die Möglichkeit einer fehlerhaften Zuordnung. Eine solche falsche Zuordnung kann dann dazu führen, dass eine zusätzliche Arbeit für den Mitarbeiter entsteht. Zusätzlich wird dann eine Korrektur benötigt und somit wird die Aufgabe doppelt durchgeführt.

Zusammenfassend lassen sich aus der Analyse des Ist-Prozesses mehrere zentrale Problembereiche ableiten. Die wichtigste Herausforderung ist das häufige Fehlen der Auftragsnummer auf den Dokumenten. Dadurch ist eine direkte Zuordnung zu einem Auftrag nicht möglich. Zudem gibt es mehrere manuelle Tätigkeiten, die durchgeführt werden müssen, angefangen beim Einscannen von Papierbelegen über die Ablage bis hin zur Prüfung und manuellen Zuordnung der Dokumente. Das Problem wird durch die teilweise hohe Anzahl an Dokumenten pro Auftrag verstärkt.

Aus diesen Problemen heraus ergibt sich der Bedarf einer Unterstützung der Dokumentenzuordnung. Die im Dokument vorhandenen Angaben sollen ausgewertet und daraus ein Auftrag ermittelt werden, der dem Benutzer vorgeschlagen wird. Die endgültige Zuordnung soll dabei nicht entfallen, sondern bestätigt und kontrolliert werden können. Die daraus folgenden Anforderungen werden im nächsten Abschnitt festgehalten.

2.3 Anforderungen an den Prototyp

Ausgehend von der Ausgangssituation und den im Ist-Prozess analysierten Problemen besteht das Ziel des Projektes darin, die bisher manuell durchgeführte Zuordnung von Dokumenten zu Aufträgen durch einen systemgestützten Prozess zu unterstützen. Dabei soll nicht der gesamte Auftragsdurchlauf neugestaltet werden, sondern die Brücke zwischen eingegangenem Fremdbeleg und vorhandenem Auftrag.

Ein Bestandteil der Anforderungen besteht zunächst darin, ein neues Dokument digital für die weitere Verarbeitung bereitzustellen. Papierbelege sollen dazu eingescannt werden können. Liegt das Dokument bereits digital vor, soll der Scanvorgang entfallen. Entgegengenommen werden mindestens PDF- sowie Bilddateien (JPEG, PNG).

Es wird nicht der gesamte Beleginhalt als umfassende Menge an Informationen extrahiert. Gesucht wird die Auftragsnummer hinter festgelegten Bezeichnungen. Fehlt eine solche Bezeichnung, darf keine beliebige Zahl im Dokument als Auftragsnummer geraten werden.

Ein weiteres Ziel besteht darin, zu prüfen, ob auf dem Dokument eine Auftragsnummer vorhanden ist oder keine Auftragsnummer vorhanden ist. Beide Fälle müssen berücksichtigt werden. Ist eine Nummer erkannt, soll über diese Nummer in den Auftragsdaten gesucht werden. Fehlt die Nummer, soll eine Suche über andere im Beleg vorkommende Angaben möglich bleiben.

Auf Grundlage dieser Ergebnisse soll dem Benutzer ein Zuordnungsvorschlag angezeigt werden. Dadurch soll die bisher vollständig manuell durchgeführte Suche nach dem passenden Auftrag durch eine systemgestützte Ermittlung unterstützt werden. Der Benutzer erhält somit einen Vorschlag, den er anschließend überprüfen kann.

Ein wichtiges Ziel ist dabei, dass die endgültige Entscheidung weiterhin beim Benutzer liegt. Nach der Anzeige des Zuordnungsvorschlags kann der Benutzer diesen bestätigen oder nicht bestätigen. Dadurch soll sichergestellt werden, dass ein vom System ermittelter Vorschlag nicht ohne Kontrolle übernommen wird.

Wird der Zuordnungsvorschlag bestätigt, soll die Verknüpfung festgehalten werden. Ein Schreiben in das Archiv von Spedifix und eine Aktualisierung der Auftragsdatenbank sind nicht gefordert. Wird der Zuordnungsvorschlag nicht bestätigt, soll weiterhin eine manuelle Zuordnung möglich sein. Damit werden auch die Fälle berücksichtigt, in denen der ermittelte Vorschlag nicht den Vorstellungen des Benutzers entspricht. Die Anforderungen, an denen der Prototyp in Kapitel 6 gemessen wird, sind in Tabelle 1 zusammengefasst.

Tabelle 1: Anforderungen an den Prototyp (Quelle: eigene Darstellung)

Nr	Anforderung	Inhalt
1	Formate	PDF sowie mindestens JPEG und PNG
2	Bereitstellung	Papier scannen, bereits digitale Dateien ohne Scan übernehmen
3	Text	Zuerst eingebetteter Text, sonst Zeichenerkennung
4	Nummer	Nur hinter festgelegten Bezeichnungen, keine geratene Zahl
5	Suche	Mit erkannter Nummer über die Auftragsdaten, ohne Nummer keine stillschweigende Buchung
6	Vorschlag	Höchstens ein begründeter Zuordnungsvorschlag
7	Bestätigung	Speichern erst nach Bestätigung, sonst manuelle Wahl möglich
8	Abgrenzung	Keine Handschrifterkennung, keine produktive Spedifix-Umgebung, kein Schreiben ins Belegarchiv

Insgesamt soll der bisherige manuelle Bearbeitungsaufwand bei der Suche reduziert und die Zuordnung von Dokumenten systematisch unterstützt werden. Während im Ist-Prozess insbesondere die manuelle Prüfung und Zuordnung den gesamten Schritt darstellt, sollen Informationsgewinnung, Abgleich mit den vorhandenen Daten und die Erstellung eines Zuordnungsvorschlags durch das System unterstützt werden. Der Benutzer bleibt als Kontrollinstanz eingebunden. Diese Anforderungen bilden den Maßstab für die Bewertung in Kapitel 6. Der fachliche Soll-Prozess dazu folgt in Kapitel 4.

3 Literaturüberblick

Bevor das konkrete Konzept für die Implementierung dieses Projekts festgelegt werden kann, ist eine Betrachtung der bestehenden Literatur erforderlich. Dieses Kapitel verschafft einen Einblick über Grundlagen und bestehende Verfahren, die für die Dokumentenerfassung, Extraktion sowie für die Zuordnung von Belegen wichtig sind. Damit soll grundlegend ein Überblick über relevante Forschungsinhalte gewonnen werden, um die wesentlichen Grundlagen für das vorliegende Projekt aufzubereiten.

3.1 Dokumentenverarbeitung

Im Zuge der Digitalisierung erfolgt die Verarbeitung und Archivierung wichtiger Dokumente wie Rechnungen oder auch Lieferbescheinigungen zunehmend digital, was anhand von Spedifix ersichtlich ist. Dennoch liegen die jeweiligen Papiere nicht immer digital vor, sondern zunächst nur als Papierdokumente, welche im Nachhinein manuell eingescannt werden müssen (siehe Abschnitt 2.1). Für das zu entwickelnde Dokumentenverarbeitungssystem ist der Verarbeitungsmechanismus der importierten Belege von besonderer Bedeutung. Die eingehenden Papiere müssen zunächst so aufbereitet werden, dass eine maschinell verarbeitbare Textgrundlage geschaffen wird. In diesem Abschnitt wird mit Blick auf die bestehende Literatur grundlegend beleuchtet, wie die Inhalte von Dokumenten erkannt und verarbeitet werden können.

Grundsätzlich kann im Rahmen der automatisierten Dokumentenverarbeitung zwischen zwei zentralen Arten von PDF Dateien differenziert werden. In dieser Hinsicht kann ein Dokument entweder von Beginn an als elektronische Datei vorliegen oder als Abbild (z.B. als Scan) des papierbasierten Dokuments (vgl. Ingram et al. 2024, S. 176). In diesem Zusammenhang werden im Vergleich zu Dokumenten, die aus einer ursprünglich analogen Form hervorgehen, digital erzeugte Dateien als „born-digital“ (Ingram et al. 2024, S. 176) PDF bezeichnet. Diese Beobachtung ist in Hinblick auf PDF Dokumente besonders relevant. Der Text einer PDF, die vorher in Papierform vorlag und eingescannt wurde, steht für ein Computersystem in diesem Fall nicht unmittelbar als Zeichenkette bereit, sondern lediglich als Bildinformation (vgl. Ingram et al. 2024, S. 176 ff.). Bei bildbasierten Dokumenten muss daher zunächst eine Erkennung des dargestellten Textes erfolgen (vgl. Hamad und Kaya 2016, S. 244). Somit ist bei der automatisierten Dokumentenverarbeitung diese Unterscheidung wesentlich, um zu entscheiden, wie der Text in den nächsten Schritten verarbeitet werden muss.

Für diesen Zweck ist der Einsatz von Optical Character Recognition (OCR) weit verbreitet (vgl. Hamad und Kaya 2016, S. 244). Bildbasierte Dokumente liegen zunächst als Pixeldaten vor und damit sich der darin enthaltene Text später maschinell verarbeiten lassen kann, wird oft OCR eingesetzt (vgl. Mukherjee et al. 2023, S. 1083). Im Allgemeinen bezeichnet OCR die automatische Erkennung von gedruckten oder handschriftlichen Zeichen aus text- oder zeichenhaltigen Dokumenten sowie deren anschließende Umwandlung in eine maschinenlesbare Form (vgl. Hamad und Kaya 2016, S. 244). Die OCR Verarbeitung kann als chronologische Reihenfolge betrachtet werden (vgl. Hamad und Kaya 2016, S. 245 ff.). Nachdem das Dokument als digitale Datei vorliegt, wird das ursprüngliche Bild in einer anschließenden Vorverarbeitung hinsichtlich seiner Qualität so aufbereitet, dass die Erkennung leichter fällt (vgl. Hamad und Kaya 2016, S. 245). Dies umfasst beispielsweise die Umwandlung in Graustufen, Rauschentfernung und weiteren Maßnahmen zur Bildverbesserung, die in der Forschung beleuchtet werden (vgl. Hamad und Kaya 2016, S. 246). Die Relevanz dieser Aufbereitung zeigt sich auch in der Studie von Patel et al. (2012) am Beispiel des OCR Systems Tesseract. Diese stellen in dem Kontext fest, dass Graustufenbilder bei der Kennzeichenerkennung von Autos im Schnitt besser abschneiden als Farbbilder (vgl. Patel et al. 2012, S. 52).

Die Verarbeitung von Dokumentbildern ist dabei mit unterschiedlichen Qualitätsmerkmalen verknüpft, wobei die zunehmende Nutzung neuer Erfassungstechnologien zu einer größeren Anzahl und Vielfalt an Dokumentbildern geführt hat (vgl. Alaei et al. 2023, S. 2 f.). Hier wird deutlich, dass Dokumente nicht notwendigerweise unter identischen Aufnahmebedingungen entstehen und daher hinsichtlich ihrer optischen Eigenschaften variieren (vgl. Alaei et al. 2023, S. 8). Somit muss bei Dokumentenzuordnungssystemen beachtet werden, dass eine gleiche Qualität und Struktur der Eingangsdokumente nicht vorausgesetzt werden können. Für das vorliegende Projekt ist dies insofern relevant, dass Zusatzdokumente im Zuge eines betrieblichen Prozesses entstehen und dies nicht notwendigerweise unter den gleichen Bedingungen. Ein Dokumentbild kann daher beispielsweise durch die Aufnahme- oder auch Scanbedingungen beeinträchtigt werden (vgl. Alaei et al. 2023, S. 8). Auch mit Blick auf das Projekt sind unterschiedliche Formate möglich, da wiederum auch verschiedene Technologien wie Handys, Kameras und Scanner eingesetzt werden (vgl. Alaei et al. 2023, S. 2). In der Forschung werden dabei unterschiedliche Arten von Dokumentdegradationen untersucht (vgl. Alaei et al. 2023, S. 4 ff.). Zu den Beeinträchtigungen eines Dokumentes gehören dabei Rauschen, unzureichender Kontrast, Verzerrungen oder auch andere Bearbeitungen der Originaldarstellung, welche sich auf die späteren Verarbeitungsschritte auswirken können (vgl. Alaei et al. 2023, S. 5 f.). Im Projektkontext könnte in einem schlecht erfassten Dokumentbild beispielsweise eine Ziffer nicht korrekt erkannt worden sein. Wenn diese Ziffer dann als Grundlage für den Datenbankabgleich verwendet wird, wird dies zu falschen Zuordnungsvorschlägen führen.

Nach der Vorverarbeitung folgt die Segmentierung, wobei das ursprüngliche Dokumentbild in relevante Textbereiche, Textzeilen, Wörter und in einzelne Zeichen unterteilt wird (vgl. Hamad und Kaya 2016, S. 246). Diesbezüglich können Top-down, Bottom-up und hybride Verfahren unterschieden werden, wodurch z.B. Tabellen, Abbildungen und Text voneinander differenziert vorliegen, um OCR auf den relevanten Bereich anwenden zu können (vgl. Kaur et al. 2013, S. 421). Beim Top Down Ansatz wird das Dokument als Ganzes betrachtet und in einzelne Teilbereiche zerlegt, wohingegen Bottom-up Ansätze einzelne relevante Bildpunkte identifizieren und im Anschluss zu größeren Bausteinen wie Zeilen und Wörtern zusammenfügen (vgl. Kaur et al. 2013, S. 421). Hybride Verfahren kombinieren beide Vorgehensweisen. In diesem Kontext wird darauf hingewiesen, dass die Genauigkeit von OCR im Nachgang unter anderem von der Bildvorverarbeitung und der Segmentierung abhängt (vgl. Patel et al. 2012, S. 50). Besonders problematisch können Bilder mit komplexen Hintergründen, unterschiedlichen Schriftgrößen oder auch untypischen Schriftarten sein (vgl. Alaei et al. 2023, S. 5 f.).

Nach der Segmentierung werden die isolierten Zeichen normalisiert. Dabei werden Größe und Darstellung der Zeichen vereinheitlicht und überflüssige Bildinformationen reduziert (vgl. Hamad und Kaya 2016, S. 246 ff.). In diesem Schritt werden auch charakteristische Eigenschaften der Zeichen bestimmt und mittels Merkmalsvektoren dargestellt. In dieser Hinsicht kann zwischen zwei zentralen Arten unterschieden werden (vgl. Hamad und Kaya 2016, S. 246 ff.). Statistische Merkmale beziehen sich auf die Pixelverteilung, während strukturelle Merkmale die geometrischen und topologischen Eigenschaften wie z.B. Endpunkte

oder auch Verzweigungen von Zeichen berücksichtigen. Den extrahierten Merkmalen ordnet ein Klassifikator im Anschluss eine bestimmte Zeichenklasse zu, wobei hier unterschiedliche Verfahren zum Einsatz kommen können (vgl. Hamad und Kaya 2016, S. 246 ff.).

Eine zentrale Limitation OCR basierter Ansätze besteht darin, dass solche Verfahren mit einem hohen Rechenaufwand verbunden sind und relativ begrenzt sind in Hinblick auf die Erkennung unterschiedlicher Sprachen und Dokumententypen (vgl. Kim et al. 2022, S. 1). Dabei hat ein Fehler erhebliche Auswirkungen auf die nachfolgende Verarbeitung. Insgesamt hat sich OCR jedoch in den letzten Jahren zunehmend von den klassischen merkmalsbasierten Ansätzen wegentwickelt, was die Performanz positiv beeinflusst hat (vgl. Kim et al. 2022, S. 14). Während traditionelle OCR Systeme oft auf Zeichenerkennung mit einer anschließenden Klassifizierung beruhen, sind moderne Ansätze darauf ausgerichtet den Inhalt semantisch zu verstehen sowie den strukturellen Aufbau des Eingangsdokuments zu erfassen (vgl. Kim et al. 2022, S. 7). Damit werden Methoden der Bildverarbeitung zunehmend mit der Verarbeitung natürlicher Sprache und dem maschinellen Lernen verknüpft (vgl. Li et al. 2023, S. 13096 ff.). In Hinblick auf das vorliegende Spedifix Projekt könnte neben dem erkannten Text auch dessen Anordnung im Dokument relevant sein z.B. wo sich typischerweise eine Auftragsnummer befindet. In diesem Zusammenhang zeigt die Arbeit von Xu et al. (2020) mit dem LayoutLM Ansatz, wie künstliche Intelligenz (KI) dafür eingesetzt werden kann, Text und Layout gemeinsam zu berücksichtigen (vgl. Xu et al. 2020, S. 1192 ff.). Damit konnten erste Erfolge beim Verständnis von Belegen erzielt werden (vgl. Xu et al. 2020, 1197 ff.). Auf diese Weise werden Beziehungen zwischen Überschriften, Eingabefeldern oder einzelnen Werten berücksichtigt, wodurch die OCR Methode über die reine Texterkennung hinaus zu einem umfassenderen Dokumentenverständnis erweitert wird (vgl. Xu et al. 2020, S. 1192). Dieses Modell basiert jedoch auf die von OCR extrahierten Informationen, welche als Input für das Modell fungieren, um dann als Output strukturierte Daten wiedergeben zu können (vgl. Xu et al. 2020, S. 1194 ff.). Einen OCR freien Ansatz haben dahingegen Kim et al. (2022) mit ihrem Document Understanding Transformer (Donut) entwickelt (vgl. Kim et al. 2022, S. 1 ff.). Dabei verarbeitet es ein Dokumentbild mithilfe eines Transformer Modell und leitet mithilfe eines vorherigen Trainings automatisch die relevanten Informationen für die jeweilige Aufgabe ab, ohne eine OCR Komponente einzubinden (vgl. Kim et al. 2022, S. 3 ff.). Ein separater OCR Einsatz ist damit nicht mehr erforderlich, wodurch Fehler einer vorgelagerten Texterkennung vermieden werden.

Insgesamt zeigt sich, dass OCR zwar immer noch als weitverbreitete Grundlage gilt, jedoch in Hinblick auf komplexe Dokumente auf seine Grenzen stoßen kann. Moderne Verfahren wie LayoutLM oder Donut gehen über die automatische Texterkennung hinaus und berücksichtigen dabei das ganzheitliche Dokument und semantische Bedeutungen von Texten. Diese setzen jedoch Training eines entsprechenden Modells sowie gelabelte Trainingsdaten voraus.

3.2 Informationsextraktion

Nach OCR liegt eine textuelle Repräsentation des ursprünglichen Dokuments bereit. In den meisten Fällen ist dies jedoch nicht das zentrale Ziel. In dem vorliegenden Szenario des

Spedifix Unternehmens ist eine Dokumentenzuordnung angestrebt. Ein direktes Matching auf Basis des gesamten Textes wäre hier nicht sinnvoll, da durch OCR sämtliche Textbestandteile des Eingangsdokuments erfasst werden und damit auch unmittelbar die Informationen, die für die Zuordnung nicht relevant sind. In dieser Hinsicht spielt die Informationsextraktion eine entscheidende Rolle. Grundsätzlich zielt die Informationsextraktion darauf ab, relevante Informationen aus unstrukturierten Dokumenten zu identifizieren in einer strukturierten Form (z.B. in Form einer Zuweisung zu Entitäten) darzustellen (vgl. Xu et al. 2024, S. 1). Damit reduziert die Informationsextraktion die im Nachgang benötigten Informationen auf das Wesentliche. In diesem Kapitel sollen daher Grundlagen zur Informationsextraktion sowie ausgewählte Verfahren in der bestehenden Forschung beleuchtet werden.

Regelbasierte Verfahren weisen in der Forschung zur Informationsextraktion eine hohe Relevanz auf. Diese arbeiten mit vordefinierten Regeln, die als Muster fungieren und anhand derer Texte letztlich auf bestimmte sprachliche oder strukturelle Muster untersucht werden (vgl. Kluegl et al. 2016, S. 2 f.). Dabei gibt es unterschiedliche Formen zur Erkennung wie z.B. reguläre Ausdrücke, die mithilfe einer bestimmten Syntax dargestellt werden können (vgl. Kluegl et al. 2016, S. 9 f.). Solche regulären Ausdrücke stellen dabei eine Möglichkeit dar, Zeichenfolgen mit einer festgelegten Syntax abzugleichen, was sich bei Wörtern mit einer relativ konsistenten syntaktischen Struktur wie z.B. Nummern oder auch Datumsangaben besonders eignet (vgl. Kluegl et al. 2016, S. 10). In der Praxis werden regelbasierte Verfahren u.a. für die sogenannte Named Entity Recognition (NER) eingesetzt (vgl. Druzhkina et al. 2016, S. 29 f.). Bei NER wird in Texten anhand von regulären Ausdrücken versucht bestimmte Wörter zu extrahieren und diese der definierten Entitätsklasse (z.B. Name, Person, Ort) zuzuordnen (vgl. Li et al. 2020, S. 50 f.). Analog dazu gibt es auch die Relation Extraction, welche beispielsweise versucht die Beziehung zwischen Entitäten aus dem Text zu extrahieren (vgl. Jiang 2012, S. 22). Dennoch listet die Forschung auch Grenzen solcher regelbasierten Ansätze auf. Der Aufwand für die Entwicklung der entsprechenden Regeln ist relativ hoch und dieser würde mit einer zunehmenden Komplexität der Texte steigen (vgl. Jiang 2012, S. 14). Außerdem sind solche definierten Muster meist abhängig von dem jeweiligen Themenbereich, für den diese konstruiert wurden. Das Muster müsste sich bei einem Wechsel der Aufgabe stets anpassen, anderenfalls würde die Performanz sinken (vgl. Jiang 2012, S. 34).

Im Zuge der Technologieentwicklung der letzten Jahre haben sich auch maschinelle Lernverfahren und insbesondere Deep Learning Ansätze für die Informationsextraktion etabliert (vgl. Zong et al. 2021, S. 9). Bei NER können diese neuen Modelle beispielsweise anhand von Testdaten mit Labels lernen, welche Wörter bestimmten Entitätsklassen wie Person oder Ort zuzuschreiben sind (vgl. Li et al. 2020, S. 50 ff.). Außerdem verdeutlichen Li et al. (2020) hierbei, dass im Vergleich zu festen Regeln sprachliche Zusammenhänge aufgrund von Deep Learning Verfahren stärker berücksichtigt werden können, was sich mit einer festen Menge an Regeln nur schwer abbilden lässt (vgl. Li et al. 2020, S. 55 f.). Parallel dazu steigt jedoch auch der Bedarf an geeigneten Trainingsdaten (vgl. Li et al. 2020, S. 63). Mit der Entwicklung von LLMs hingegen haben sich diesbezüglich auch noch weitere Ansätze für die Informationsextraktion entwickelt. Xu et al. (2024) geben dabei auch einen umfassenden Überblick über generative Informationsextraktionsmodelle, die beispielsweise Named Entity

Recognition und weitere Formen von Extraktionen wie relation extraction oder auch event extraction vereinen und gemeinsam modellieren (vgl. Xu et al. 2024, S. 3 ff.). Dadurch besteht die Möglichkeit unterschiedliche Extraktionsaufgaben mit einem einheitlichen Modell abzudecken (vgl. Xu et al. 2024, S. 4). Ältere Verfahren, die klassisch maschinelle Lernverfahren nutzen, benötigen in dem Kontext Trainingsdaten mit den richtigen Labels, wohingegen LLMs über entsprechende Prompts eine Informationsextraktion durchführen können, ohne für jede Aufgabe ein separates Modell mit Daten trainieren zu müssen (vgl. Xu et al. 2024, S. 1 ff.). Diese höhere Flexibilität moderner Verfahren birgt jedoch auch Herausforderungen. Da LLM Modelle abhängig von ihren Trainingsdaten sind, kann es auch zu fehlerhaften Outputs kommen (vgl. Xu et al. 2024, S. 7). Einen Vergleich zwischen regelbasierter Extraktion und dem Einsatz von LLMs wird in der Studie von Principe et al. (2025) am Beispiel von Extraktionen aus italienischen Immobilien-Auktionsdokumenten beleuchtet (vgl. Principe et al. 2025, S. 243). Zwar hatte das regelbasierte System hier die geringeren Ausführungskosten mit zuverlässigen Ergebnissen, jedoch zeigten die untersuchten Claude Modelle eine vergleichbare und teilweise bessere Extraktionsqualität bei geringerem Entwicklungs- und Wartungsaufwand (vgl. Principe et al. 2025, S. 251 f.). Principe et al. (2025) kommen daher zum Schluss, dass LLMs für den untersuchten Anwendungsfall einen besonders günstigen Trade off zwischen Performance, Kosten und Entwicklungsaufwand bereitstellen (vgl. Principe et al. 2025, S. 250 f.).

Zusammenfassend kann anhand dessen abgeleitet werden, dass Informationsextraktion einen wichtigen Schritt vor dem eigentlichen Matching Teil darstellt, um aus dem OCR Input einen Output mit relevanten Informationen zu generieren. Regelbasierte Verfahren eignen sich für festgelegte Muster wie eine Auftragsnummer sowie für einfach strukturierte Dokumente. Ansätze, die auf Deep Learning basieren, würden zwar untypische Zeichen und verschiedene Texte in Hinblick auf ihre semantische Komplexität umfassender verarbeiten, sind jedoch nur in einem Rahmen mit den entsprechenden Ressourcen umsetzbar.

3.3 Matching- und Zuordnungsverfahren

Unter Matching wird allgemein die Zuordnung bzw. Paarbildung von Objekten verstanden, die zusammengehören (vgl. Gerards 1995, S. 135). In Zusammenhang mit dem vorliegenden Projekt sollen die extrahierten Informationen aus dem Eingangsdokument dem passenden Auftrag zugeordnet werden. Mit Blick auf die Forschung können sich je nach Problemstellung unterschiedliche Verfahren eignen. Daher widmet sich dieser Abschnitt den unterschiedlichen Matching Strategien.

Eine grundlegende Möglichkeit des Matchings sind String Matchings. Hierbei wird zunächst zwischen Exact String Matching, das auf eine vollständige Übereinstimmung einer Zeichenkette abzielt und Approximate String Matching, das nach Zeichenfolgen sucht, die einem Suchmuster ähnlich sind, differenziert (vgl. Hakak et al. 2019, S. 69615 ff.). Zu den bekannten Verfahren des exakten Matchings gehört beispielsweise der Knuth Morris Pratt Algorithmus (vgl. Knuth et al. 1977, S. 323 ff.). Bei exakten Verfahren muss jedoch beachtet werden, dass diese entsprechend keine Toleranz gegenüber Abweichungen besitzen (vgl.

Hakak et al. 2019, S. 69616 f.). Diese Limitation wird durch Fuzzy Matching Verfahren aufgegriffen. Statt einen exakten Abgleich zu führen, berechnet diese Strategie den Grad der Ähnlichkeit von Zeichenketten, wodurch auch Matches mit minimalen Unterschieden berücksichtigt werden (vgl. Kalluru 2022, S. 685). Ein konkretes Beispiel hierfür ist die Levenshtein Distanz, bei der die Anzahl von Operationen zum Einfügen, Löschen oder Ersetzen gezählt werden, die notwendig sind, um eine Zeichenkette in eine andere umzuwandeln (vgl. Kalluru 2022, S. 685 f.). In diesem Fall betonen Hakak et al. 2019 in ihrer Studie, dass die Wahl des Algorithmus von unterschiedlichen Eigenschaften abhängt wie z.B. von der Komplexität des Problems (vgl. Hakak et al. 2019, S. 69615 f.). Bei unterschiedlichen und realen Datenbeständen können exakte Verfahren daher an ihre Grenzen treffen (vgl. Hakak et al. 2019, S. 69615 f.).

Dabei können Ergebnisse von Matching Verfahren auch in Form von Schwellenwerten interpretiert werden, wie das sowohl in der Studie von Papadakis et al. (2023) als auch von Rozinek et al. (2025) gemacht wurde. Anhand eines Schwellenwerts wird entschieden, ab welchem Wert ein Kandidat als ähnlich gilt (vgl. Rozinek et al. 2025, S. 5 f.). Die Verwendung eines festen Schwellenwerts ist allerdings nicht unproblematisch (vgl. Papadakis et al. 2023, S. 1391).

Einen weiteren Lösungsansatz bietet die Entity Resolution, auch bekannt als Record Linkage (vgl. Barlaug und Gulla 2021, S. 4). Das zentrale Ziel besteht darin, Datensätze aus unterschiedlichen Quellen miteinander zu verknüpfen, wenn sie dieselbe reale Entität repräsentieren (vgl. Barlaug und Gulla 2021, S. 1 ff.). Bei vielen Datensätzen, die zugewiesen werden müssen, kann dabei jedoch ein Effizienzproblem auftauchen. Würden beispielsweise alle Dokumente bzw. extrahierten Informationen mit allen vorhandenen Aufträgen wie im Fall von Spedifix verglichen werden, wächst die Anzahl der möglichen Vergleiche sehr stark an (vgl. Barlaug und Gulla 2021, S. 2). Um diesen Datenraum einzugrenzen, wird in der Arbeit von Karr et al. (2019) die sogenannte Blocking Strategie beleuchtet. Hauptsächlich geht es darum den Rechenaufwand bei der Entity Resolution Strategie zu reduzieren und nur die Datensatzpaare miteinander zu vergleichen, die in bestimmten Merkmalen, den definierten Blocking Variablen, übereinstimmen (vgl. Karr et al. 2019, S. 3). Die Wahl des Blocking Merkmals ist dabei ein wichtiger Faktor. Karr et al. (2019) zeigen anhand realer Daten, dass unterschiedliche Blocking Strategien zu unterschiedlichen Ergebnissen führen können (vgl. Karr et al. 2019, S. 10 ff.). Neben dem klassischen Blocking wurde beispielsweise in der Arbeit von Maciejewski et al. (2025) auch Progressive Entity Matching untersucht. Hier werden die potenziellen Übereinstimmungen zwischen Datensätzen priorisiert und schrittweise überprüft, wobei die wahrscheinlichsten Matches zuerst betrachtet werden (vgl. Maciejewski et al. 2025, S. 4). Damit wird bei einer begrenzten Prüfungskapazität beabsichtigt möglichst viele Matches frühzeitig zu finden. Im Kontext des vorliegenden Projekts kann dies insofern relevant sein, wenn große Datenbestände oder zeitkritische Verarbeitungen berücksichtigt werden müssen (vgl. Maciejewski et al. 2025, S. 4). Für das Matching sind hingegen auch hybride Ansätze möglich, die den Einsatz von Mensch und Maschine vereinen. So wäre ein möglicher Ansatz, die einfacheren Paare maschinell bearbeiten zu lassen und risikoreiche Instanzen über eine manuelle Prüfung durch den Menschen durchlaufen zu lassen (vgl. Hou et al. 2018, S. 374 f.).

Neue Ansätze besonders im Bereich von Entity Matching machen hingegen auch zunehmend Gebrauch von Large Language Models (LLM), um die Grenzen von klassischen stringbasierten Verfahren zu überwinden (vgl. Wang 2024, S. 1 ff.) Während klassische Methoden wie die Levenshtein Distanz primär auf syntaktischer Ähnlichkeit beruhen (vgl. Kalluru 2022, S. 685 f.), erlauben neuronale Netze und LLMs eine semantische Betrachtung der Daten (vgl. Zong et al. 2021, S. 231 ff.). In dieser Hinsicht ermöglichen Deep Learning Modelle eine automatische Extraktion von Merkmalen, wodurch das Matching weniger auf manuell definierte Regeln angewiesen ist (vgl. Barlaug und Gulla 2021, S. 2 f.). Dafür werden diverse neuronale Architekturen wie Recurrent Neural Network (RNN) sowie Transformermodelle wie BERT eingesetzt (vgl. Barlaug und Gulla 2021, S. 2ff). Auch Wang (2024) untersuchte den Einsatz von LLMs am Beispiel von ChatGPT im Kontext von Fuzzy String Matching. In einem Experiment wurde mithilfe verschiedener Prompts geprüft, ob unterschiedlich geschriebene Bezeichnungen einander zugeordnet werden können. Dabei konnte eine Steigerung der Precision erzielt werden und dies ohne ein vorheriges Training mit den entsprechenden Daten (vgl. Wang 2024 S. 3 ff.). Die Ergebnisse zeigen zudem, dass semantische Ähnlichkeiten erkannt werden, wozu rein zeichenbasierte Verfahren nicht in der Lage sind (vgl. Wang 2024, S. 2 f.).

Die Betrachtung der verschiedenen Matching- und Zuordnungsverfahren zeigt, dass es kein Verfahren gibt, welches sich stets für ein Problem anwenden lässt. So hängt die Auswahl teilweise sehr von der Qualität, Struktur und Eindeutigkeit der Daten ab. Diese Erkenntnis muss auch im vorliegenden Projekt in Hinblick auf die unterschiedlichen Eingangsdokumente beachtet werden. Während exakte Verfahren bei eindeutig vorliegenden Merkmalen eine hohe Zuverlässigkeit bieten, ermöglichen hingegen Fuzzy Methoden oder auch LLMs mit Berücksichtigung von semantischen Bedeutungen einen Lösungsansatz für fehlerhafte oder abweichende Daten. Für das vorliegende Projekt ist dabei der hybride Ansatz von Mensch und Maschine in Hinblick auf die Anforderung einer manuellen Zuordnung (siehe Tabelle 1) besonders relevant. Insgesamt lässt sich daher für das Projekt ableiten, dass eine Auswahl der Strategie auf den Geschäftsprozess und auf die Merkmale der Daten des Unternehmens abgestimmt sein muss.

3.4 Projekteinordnung

Der bisherige Stand in der Literatur zeigt, dass die automatisierte Verarbeitung und Zuordnung von Objekten bereits Gegenstand zahlreicher Forschungsarbeiten sind. Gleichzeitig wird deutlich, dass bestehende Studien häufig auf spezifische Problemstellungen und Datenstrukturen zugeschnitten sind.

Für das vorliegende Projekt steht daher nicht die Entwicklung eines völlig neuen Algorithmus für Dokumentenzuordnungen im Vordergrund. Mit diesem IT-Studienprojekt soll vielmehr eine Lösung entwickelt werden, die einen Weg findet, bestehende Ansätze in einen konkreten Geschäftsprozess zu übertragen und dabei stets die realen Anforderungen und Probleme eines Betriebs zu berücksichtigen.

Die in der Literatur beschriebenen Herausforderungen hinsichtlich Datenqualität und unterschiedlicher Dokumentenformate finden sich dabei praktisch am Beispiel von Spedifix wieder. Im Speditions- und Logistikumfeld entsteht durch die Vielzahl an Eingangsdokumenten organisatorisch ein hoher Aufwand. Die Lösung soll dabei auf diese Umstände ausgelegt sein und die Arbeitsabläufe von Spedifix effizienter gestalten. In diesem Fall spielen die Anforderungen und aktuellen Arbeitsweisen der Mitarbeiter eine zentrale Rolle. Es soll eine möglichst intuitive Nutzung sichergestellt werden, die deren Arbeitsalltag unterstützt und nicht durch Komplexität erschwert. Aus diesem Grund bilden die Analyse des Ist-Prozesses und die Anforderungsanalyse aus Abschnitt 2 eine wesentliche Grundlage für die technische Implementierung. Mit dem Literaturüberblick kombiniert soll eine ideale Verknüpfung der verschiedenen Strategien für den vorliegenden Anwendungsfall gefunden werden. Die technische Implementierung baut dabei auf das Zusammenspiel der drei Bereiche Texterkennung, Informationsextraktion und Matching auf, welche in diesem Kapitel inhaltlich separat aufbereitet wurden. Jedoch müssen in diesem Rahmen auch die technischen Möglichkeiten sowie Grenzen des Projekts berücksichtigt werden. Dazu zählt die Verfügbarkeit einer Testdatenbank samt Auftragsdaten, die Struktur und Qualität der Daten sowie der zeitliche Entwicklungsaufwand. Nicht jedes Verfahren lässt sich unter diesen Voraussetzungen sinnvoll einsetzen. So setzen einige moderne Ansätze umfangreiche Trainingsdaten voraus, während andere eine höhere Komplexität mit sich bringen, als es für den jeweiligen Use Case erforderlich ist (siehe Abschnitt 3.3).

Insgesamt wird daher intendiert, die drei Forschungsbereiche auf den Anwendungsfall von Spedifix zuzuschneiden und zu vereinen. Dabei sollen die Erkenntnisse der Forschung sowie die betrieblichen Anforderungen als Fundament für die Entwicklung der Lösung fungieren.

4 Konzeption des Systems

Kapitel 4 überführt die Anforderungen aus Abschnitt 2.3 und die in Kapitel 3 gesichteten Ansätze in ein Fachkonzept. Es wird festgelegt, wie die Zuordnungshilfe arbeiten soll, noch nicht, womit einzelne Funktionen programmiert werden. In dem Abschnitt 4.1 wird der Soll-Prozess beschrieben. Im darauffolgenden Abschnitt 4.2 wird die Zerlegung in Extraktion, Matching und Prüfoberfläche behandelt. Abschnitt 4.3 geht auf das Datenmodell zwischen Beleg, Vorschlag und bestätigter Zuordnung ein. Technische Details der Module folgen in Kapitel 5.

4.1 Soll Prozessmodellierung

Auf Grundlage der zuvor beschriebenen Zielsetzung wurde ein Soll-Prozess entwickelt, der die bisher manuelle Zuordnung von Fremdbelegen durch eine systemgestützte Verarbeitung unterstützen soll. Die Modellierung baut auf dem Ist-Prozess auf und verändert diejenigen Schritte, die einen hohen manuellen Aufwand verursachen. Technische Verfahren und die Bildung eines Kennwerts werden in den folgenden Kapiteln behandelt.

Der Prozess beginnt mit dem Ereignis, dass ein Fremddokument eingetroffen ist. Über einen XOR-Konnektor wird zwischen einem Papierbeleg und einem bereits digitalen Beleg unterschieden. Ein Papierbeleg wird eingescannt. Ein digitaler Beleg wird in einem Ordner abgelegt. Dadurch entfällt der Scan. Nach beiden Eingangswegen liegt das Dokument digital vor. Es wird nicht sofort manuell zugeordnet, sondern zunächst systemgestützt ausgewertet.

Anschließend wird der Belegtext extrahiert. Enthält die Datei bereits einen Text, wird dieser gelesen. Andernfalls greift eine Zeichenerkennung als Rückfall. Eine Definition der Verfahren gehört in Kapitel 3. Als Ergebnis liegt ein lesbarer Belegtext vor. Aus diesem Text wird die Auftragsnummer hinter festgelegten Bezeichnungen gesucht. Weitere Angaben des Belegs werden nicht als eigene Felder extrahiert. In der Modellierung wird dieser Schritt als „Suche Auftragsnummer hinter Label“ dargestellt.

Danach wird über einen XOR-Konnektor unterschieden, ob eine Auftragsnummer vorhanden ist oder nicht. In beiden Fällen folgt ein Matching mit Abgleich der Auftragsdaten. In der Modellierung wird dieser Schritt als „Führe Matching mit Abgleich der Auftragsdaten durch“ dargestellt. Ziel ist ein Zuordnungsvorschlag, nicht die endgültige Zuordnung.

Nach dem Matching wird der Vorschlag angezeigt. In der Modellierung entspricht das der Funktion „Zeige Zuordnungsvorschlag an“. An dieser Stelle liegt die Schnittstelle zwischen der systemgestützten Verarbeitung und der Entscheidung des Benutzers.

Im Anschluss prüft der Benutzer den Vorschlag. Die Modellierung unterscheidet nach der Funktion „Prüfe Zuordnungsvorschlag“ drei Ereignisse. Wird der Vorschlag bestätigt, wird die Zuordnung gespeichert. In der Modellierung entspricht das der Funktion „Speichere bestätigte Zuordnung“. Ein Schreiben in das Belegarchiv ist nicht Teil dieses Prozesses. Wird der Vorschlag nicht bestätigt, wird eine manuelle Zuordnung durchgeführt. Somit kann der Benutzer das Dokument einem anderen Auftrag zuordnen. Bleibt der Vorschlag offen, wird das Dokument ohne Zuordnung belassen. Eine nicht bestätigte Zuordnung wird nicht übernommen.

Die drei Wege laufen in der Funktion „Halte Ergebnis fest“ zusammen. Damit wird festgehalten, ob der Beleg bestätigt, manuell zugeordnet oder ohne Zuordnung offengelassen wurde. Die systemgestützte Verarbeitung ersetzt die Entscheidung des Mitarbeiters nicht, sondern unterstützt sie. Der beschriebene Soll-Prozess ist in Abbildung 2 als ereignisgesteuerte Prozesskette dargestellt.




Abbildung 2: Soll-Prozess der systemgestützten Belegzuordnung (Quelle: eigene Darstellung)

4.2 Systemarchitektur

SmartAssign ist eine lokale Desktop-Anwendung, die eingehende Belege aufbereitet, mit Aufträgen aus einer Datenbank abgleicht und dem Nutzer Zuordnungsvorschläge zur Bestätigung anbietet. Entgegengenommen werden dabei sowohl PDF- als auch Bilddateien (mindestens JPEG und PNG). Die Systemarchitektur ist in einen klar strukturierten Verarbeitungsablauf gegliedert, der in drei funktionsbestimmende Pakete eingeteilt werden kann: Dokumentenaufnahme und Textextraktion, algorithmischer Abgleich durch einen Matching-Algorithmus sowie Ergebnisanzeige mit manueller Bestätigung. In diesen Ablauf ist eine Datenbankbindung eingelagert, die einerseits die Auftrags- und Adressdaten bereitstellt und andererseits die bestätigten Zuordnungsergebnisse ablegt. Dabei handelt es sich für den Prototyp um eine getrennte Entwicklungsdatenbank, die die Spedifix Datenbank nachstellt, nicht aber um die Spedifix-Umgebung selbst.

Eingangsdokumente sind die nachgelagerten Belege des Auftragsdurchlaufs, etwa Rechnungen, Frachtbriefe, Lieferscheine oder Schadensmeldungen (vgl. Fiebach 2026, S.1). Eine Unterscheidung nach Typ findet in der Architektur nicht statt. Die Dokumente gelangen dabei auf zwei Wegen in das System. SmartAssign liest den konfigurierten Importordner. Neu abgelegte Dateien werden beim Anwendungsstart sowie nach einem Import oder einem erneuten Durchlauf verarbeitet. Beim Start, nach einem Import und bei einem erneuten Durchlauf wird der Importordner gelesen. Die Verarbeitung läuft im Hintergrund, damit die Oberfläche nicht blockiert. Ein dauerhafter Ordnerwächter wird nicht eingesetzt. Zum anderen können die Dokumente auch manuell über die Benutzeroberfläche importiert werden, entweder per Drag-and-Drop direkt in den Upload-Bereich der Übersichtsseite oder über eine klassische Dateiauswahl. Auch ein kompletter Ordnerimport ist dabei möglich, um gleich mehrere Dokumente gleichzeitig zu importieren. Die beiden Importwege ergänzen sich so, dass regelmäßig eingehende Dokumente automatisiert erfasst werden können, ohne dass die Möglichkeit des Direktimportes entfällt.

Der erste Bearbeitungsschritt nach dem Import ist die Textextraktion. Dafür stehen zwei sich ergänzende Verfahren zur Verfügung, die in einer Pipeline hintereinander geschaltet sind. Als primäre Methode liest ein PDF-Textscanner eingebetteten Text direkt aus dem hochgeladenen Dokument aus, technisch realisiert über die Bibliothek PyMuPDF, welche eine schnelle Extraktion von maschinenlesbarem Text ermöglicht. Voraussetzung dafür ist, dass das PDF entsprechend aufbereitet ist und digital eingebetteten Text enthält, was bei computergenerierten Dokumenten normalerweise der Fall ist.

Erfolgt die Textextraktion aus einem gescannten Dokument oder Beleg auf diesem Wege nicht ausreichend, so verwendet das System automatisch einen OCR Dienst zur Textextraktion. Die Zeichenerkennung analysiert das Dokument pixelbasiert und erkennt die Schriftzeichen direkt aus dem Bild heraus. Technisch ist dieser Fallback über Tesseract in Kombination mit der Python-Bibliothek pytesseract realisiert.

Das OCR Verfahren benötigt mehr Rechenzeit als die direkte Textextraktion, erlaubt jedoch auch die Verarbeitung von Dokumenten, die keinen eingebetteten Text enthalten. Ob OCR nach dem Import automatisch als Fallback gestartet werden soll, ist in den Systemeinstellungen

konfigurierbar. Wird OCR deaktiviert, wird bei PDFs nur noch eingebetteter Text gelesen, Bilddateien bleiben dann ohne Text, was in solchen Fällen zu lückenhaften Extraktionsergebnissen führen kann. Die auf beiden Wegen gesammelten Texte werden, sobald die Verarbeitung abgeschlossen ist, an die zentrale Anwendungslogik übergeben.

Dort wertet die Anwendung den zuvor extrahierten Text auf relevante Textpassagen aus. Eine Funktion durchsucht den Text nach bestimmten Schlüsselwörtern, den sogenannten Labels, die typischerweise vor der Auftragsnummer stehen. Diese Labels sind in den Einstellungen der Anwendung frei konfigurierbar, sodass die Erkennung an unterschiedliche Dokumentformate und interne Bezeichnungen angepasst werden kann. Die Extraktion liefert somit ein Eingangsdokument mit Dateipfad, Volltext, optionaler Auftragsnummer und dem Hinweis, ob OCR genutzt wurde. Absender und Empfänger werden dabei nicht als Entitäten aus dem Beleg erkannt; sie liegen in den Stammdaten und werden erst im folgenden Matching-Schritt daraufhin geprüft, ob ihre Felder vollständig im Belegtext vorkommen.

Der Abgleich erfolgt zuerst über die erkannte Auftragsnummer (ErfNr) in der Auftrags-tabelle. Fehlt die Nummer, wird mit einem Namensfilter gesucht, stornierte Sendungen bleiben dabei ausgeschlossen. Schlägt die Suche über eine erkannte Nummer fehl, folgt kein Namensrückfall. Die Bewertung darüber, wie gut ein Dokument mit einem Auftrag übereinstimmt, erfolgt über ein gewichtetes Scoring aus drei Merkmalen: Eine passende Auftragsnummer geht mit 60 %, das exakte Vorkommen von Absender- und Empfängeradresse je mit 20 % in den Gesamtscore ein. Weitere Felder wie Datum, Referenz oder Belegart gehen nicht in den Score und auch nicht in die Begründung ein. In der Prüfansicht werden entsprechend dieselben drei Merkmalszeilen angezeigt.

Die Zeichenketten werden vor dem Vergleich lediglich vereinheitlicht (Kleinschreibung, Zusammenziehen mehrfacher Leerzeichen). Ein Merkmal gilt anschließend ganz oder gar nicht. Auf unscharfe Ähnlichkeitsmaße und Bibliotheken wie RapidFuzz wird bewusst verzichtet, damit die Begründung eines Vorschlags zeilenweise nachvollziehbar bleibt. Das Ergebnis dieses Matching-Schrittes ist kein sortiertes Ranking, sondern ein leeres Ergebnis, ein einzelner Vorschlag oder wenige Kandidaten. Aus den berechneten Score folgen die drei Darstellungsklassen: unter 60 % „Niedrig“, ab 60 % „Mittel“ und ab 80 % „Hoch“. Liegt kein passender Auftrag vor, bleibt das Ergebnis leer, die Oberfläche kennzeichnet das als fehlende Kandidaten. Diese Schwellen ergeben sich unmittelbar aus den Gewichten und sind festgelegte Konventionen. Eine vollautomatische Zuordnung ohne menschliche Prüfung ist dabei nicht vorgesehen, unabhängig von der Zuordnungsklasse liefert das System lediglich einen Vorschlag, der aktiv vom Nutzer zur Übernahme bestätigt werden muss.

Die Zuordnungsvorschläge werden anschließend in der Benutzeroberfläche in einer Listenansicht präsentiert, in der der Nutzer jeden dieser Vorschläge prüfen, bestätigen, ersetzen oder offen lassen kann. Erst nach der aktiven Bestätigung durch den Nutzer wird die Zuordnung in der Datenbank gespeichert. Die manuelle Bestätigung ist dabei Pflicht und lässt sich nicht umgehen.

Die Datenhaltung erfolgt über Supabase auf PostgreSQL-Basis. Hierzu werden zwei verschiedene Bereiche der Datenbank genutzt: die nachgestellten Spedifix-Tabellen für

Auftrags- und Adressdaten sowie eigene Tabellen für den Verarbeitungsstatus und dem berechneten Score je importiertem Dokument, für die bestätigten Zuordnungen sowie für Konfigurationsparameter wie dem Pfad des Importordners und die Verarbeitungsoptionen. Schwellenwerte des Scores sind darin nicht hinterlegt. Die Label-Liste liegt lokal in einer Datei. Dieser Aufbau ermöglicht ein möglichst realitätsnahes Arbeiten mit der nachgestellten Spedifix-Struktur und zugleich die Speicherung der eigenen Anwendungsdaten. Eine eigene Persistenz- und Business-Logik-Schicht verarbeitet neu importierte Dokumente im Hintergrund, gleicht offene Dokumentlisten mit dem aktuellen Stand der Datenbank ab, hält häufig abgerufene Listenansichten im Cache vor und liefert die Kennzahlen für Dashboard und Auswertungsseite.

Technisch handelt es sich hierbei also um eine Applikation, die über pywebview ein grafisches Fenster für serverseitig gerenderte HTML-Seiten bereitstellt. Für das serverseitige Rendering kommt die Template-Engine Jinja2 zum Einsatz, auf clientseitige JavaScript-Frameworks wird gänzlich verzichtet, lediglich für den Upload-Drag-and-Drop und die Live-Suche kommt minimales Vanilla-JavaScript zum Einsatz. Ein schlanker lokaler HTTP-Server, der ausschließlich über die Loopback-Adresse zu erreichen ist und damit vom Netzwerk nicht erreichbar ist, ermöglicht die URL-basierte Navigation innerhalb der Anwendung und die Übergabe von Filter- und Sortierparametern über Query-Parameter. Eine Controller-Schicht interpretiert diese Parameter dann, bereitet die Daten auf und befüllt die Templates. Ein gemeinsames CSS-Regelwerk mit CSS-Variablen für Farben, Abstände und Radien sorgt dabei für ein konsistentes visuelles Erscheinungsbild über alle Seiten der Anwendung hinweg.

4.3 Datenmodell

Ein Beleg befindet sich im Prototyp zu jedem Zeitpunkt in genau einem Zustand. Zunächst liegt er ausschließlich als eingelestes Dokument vor. Anschließend kann ihm ein Vorschlag zugeordnet sein. Erst nach einer Bestätigung gilt er als bestätigt. Würden Vorschlag und Freigabe im selben Datensatz geführt und beim nächsten Lauf überschrieben werden, ginge die Information verloren, ob eine explizite Bestätigung vorgenommen wurde oder lediglich ein Score vorlag. Genau diese Differenz muss die Benutzeroberfläche abbilden. Sie dient in Kapitel 6 zugleich als Referenz für die Auswertung.

Für den Lauf durch die Verarbeitung genügen drei Objekttypen. Das Eingangsdokument bezeichnet den Zustand nach dem Einlesen und umfasst den Pfad, den gelesenen Text, die erkannte oder fehlende Auftragsnummer sowie die Angabe, ob eine Schrifterkennung ausgeführt wurde. Der Auftragskandidat wird aus der Datenbank geladen und enthält die Erfassungsnummer, eine optionale Referenz und die Adressdaten. Das Matching-Ergebnis verknüpft beide Objekte und liefert den Vorschlag, den Gesamtscore, die drei Einzelmerkmale Auftragsnummer, Absender und Empfänger sowie die zugehörigen Begründungszeilen. Eine zweite Konfidenzgröße wird nicht geführt. Die Ampelanzeige ergibt sich ausschließlich aus dem Score und ist eine Darstellungsklasse, keine Freigabe.

Die Persistenz erfolgt nicht in einer Gesamttabelle. Die Sendungsdaten liegen in den nachgestellten Tabellen `3100_Sdg_Haupt` und `3100_Sdg_Adressen` der

Entwicklungsdatenbank. Der Prototyp verwendet sie ausschließlich lesend. Der zentrale Schlüssel ist durchgängig die Erfassungsnummer. Die Unterscheidung zwischen Absender- und Empfängeradresse erfolgt über das Feld Art. Datensätze mit gesetztem Storno-Kennzeichen werden von der Suche ausgeschlossen. Eigene Zustände verwaltet der Prototyp getrennt: Die Tabelle Dokumente führt den Arbeitsstand, die Tabelle DokumentZuordnung die freigegebenen Zuordnungen.

In der Tabelle Dokumente werden Pfad und Dateiname, die erkannte Nummer, der aktuelle Vorschlag, der Score, der Status, optional eine Fehlermeldung sowie die Zeitpunkte von Import, Schrifterkennung und Matching gespeichert. Der Score wird als Zahl abgelegt. Die drei Merkmale gehören zum Matching-Ergebnis zur Laufzeit und werden in der Prüfansicht angezeigt, nicht als eigene Spalten. Die Tabelle DokumentZuordnung enthält die freigegebene Erfassungsnummer, den Score zum Zeitpunkt der Bestätigung und den zugehörigen Zeitstempel.

Der Status ist bewusst grob gehalten, damit Listenanzeige und Auswertung dieselbe Terminologie verwenden. „Prüfung erforderlich“ bezeichnet Belege, die gelesen wurden und für die gegebenenfalls ein Vorschlag vorliegt, ohne dass eine Freigabe erfolgt ist. „Keine Zuordnung“ kennzeichnet Fälle ohne Kandidaten; eine manuelle Suche bleibt möglich. „Fehlerhaft“ bezieht sich auf technische Probleme und nicht auf fachliche Unklarheiten. Ist das Matching in den Einstellungen deaktiviert, erscheint der eigene Status „Matching deaktiviert“. Läuft die Verarbeitung im Hintergrund, wird der Zwischenstand als „In Bearbeitung“ geführt und darf nicht wie „Keine Zuordnung“ erscheinen. Sonst würde eine Prüfung beginnen, bevor ein Vorschlag vorliegt. „Bestätigt“ wird nur gesetzt, wenn ein Zuordnungssatz existiert.

Einstellungen zu Schrifterkennung, Matching und Importordner werden in einem eigenen Satz verwaltet. Die Label-Liste liegt ausschließlich lokal in einer Datei. Beide Bereiche sollen änderbar sein, ohne dass das Datenbankschema angepasst werden muss.

Die beteiligten Objekte, ihre Merkmale, ihre Persistenz und ihre Rolle im Ablauf sind in Tabelle 2 zusammengefasst.

Tabelle 2: Objekt des Datenmodells (Quelle: eigene Darstellung)

Objekt	Wesentliche Merkmale	Persistenz	Rolle
Eingangsdokument	Pfad, Text, Nummer, OCR Kennzeichen	Flüchtig (Laufzeit)	Ergebnis der Extraktion
Auftragskandidat	ErfNr, Referenz, Absender, Empfänger	Gelesen aus 3100_Sdg_*	Vergleichsobjekt
Matching-Ergebnis	Vorschlag, Score, drei Merkmale	Im Belegsatz (Score + Flags)	Grundlage der Prüfung
Belegsatz	Status, Nummer, Vorschlag, Zeiten	Tabelle Dokumente	Arbeitsstand
Zuordnungssatz	ErfNr, Score, BestätigtAm	Tabelle DokumentZuordnung	Erst nach Freigabe
Sendungskopf/Adresse	ErfNr, Art, Name, Straße, PLZ, Ort	Nachgestellte Spedifix-Tabellen, nur lesend	Stammdaten
Einstellungen	OCR, Matching, Ordner	Eigener Satz, Labels lokal	Betrieb

Tabelle 2 macht die Trennung sichtbar, die den Abschnitt trägt: Extraktion und Matching erzeugen zunächst Laufzeitobjekte. Dauerhaft festgehalten werden der Arbeitsstand im Belegsatz und die Freigabe erst im Zuordnungssatz. Die Sendungsdaten bleiben fremde, nur gelesene Stammdaten.

Von der Umgebung von Spedifix wird nur der Teil des Schemas nachgebildet, der für den Abgleich erforderlich ist. Die Erfassungsnummer entspricht der Auftragsnummer aus der Aufgabenstellung. Name1, Straße, PLZ und Ort sind die Felder, die im Text gesucht werden. Mengen, Artikel und interne Archivstatus werden nicht abgebildet. Ein vollständiges Abbild des Schemas wäre für den Prototyp nicht erforderlich und würde die Struktur unnötig vergrößern.

Ein Auftrag kann mehrere Belege aufweisen. Ein Beleg besitzt jedoch höchstens eine bestätigte Zuordnung. Wird eine Bestätigung aufgehoben, wird der Zuordnungssatz gelöscht und der Beleg erneut verarbeitet. Die Datei bleibt erhalten. Eine Löschung der Datei erfolgt nur bei ausdrücklicher Anweisung. Eine ausführliche Historie verworfener Vorschläge wäre später nützlich, gehört jedoch nicht zum geforderten Umfang.

Eine eigene Klasse „Rechnung“ oder „Frachtbrief“ wird im Datenmodell nicht eingeführt. Belege werden einheitlich als Belege gespeichert. Die Dokumentgattung hat keinen Einfluss auf Tabellenstruktur oder Score-Berechnung.

Am Scan frachtbrief_3001_scan.pdf lässt sich der Ablauf darstellen. Der direkte PDF-Text ist leer, die Schrifterkennung wird ausgeführt, und die Nummer 3001 wird erkannt. Das Matching lädt die Sendung 3001 einschließlich der Adressen. Der Belegsatz erhält den Status „Prüfung erforderlich“. Nach der Bestätigung wird ein Zuordnungssatz erzeugt, der Status wechselt zu „Bestätigt“. Wird die Zuordnung aufgehoben, ist der Beleg wieder offen; Text und Datei bleiben bestehen. Kapitel 5 greift diesen Ablauf unverändert auf, wie am selben Beispiel dort gezeigt wird.

Einige Felder, die leicht zu viel modelliert würden, entfallen. Es gibt kein Benutzerfeld am Eingangsdokument, keine Mengenangaben am Auftragskandidaten und keine zweite Konfidenzgröße. Die Datei selbst wird nicht in der Datenbank gespeichert, sondern nur der Pfad. In einer gemeinsamen Tabelle würden sonst Pfade erscheinen, zu denen lokal keine Datei existiert. Die Oberfläche zeigt deshalb ausschließlich Dateien, die im eigenen Importordner vorhanden sind.

Bestätigen, Aufheben und Löschen greifen auf unterschiedliche Datensätze zu. Bestätigen legt einen Zuordnungssatz an und setzt den Status des Belegs auf „Bestätigt“. Aufheben entfernt den Zuordnungssatz und verarbeitet den Beleg erneut. Löschen entfernt Zuordnungssatz, Belegsatz und Datei, allerdings nur innerhalb des Importordners. Dateien außerhalb dieses Ordners bleiben unberührt.

Damit sind der Kernprozess und das zugehörige Datenmodell umrissen. Das Modell kommt mit wenigen Objekten aus. Erweiterungen wie lernendes Matching, ein eigener Belegtyp oder das

Schreiben in das produktive Archiv werden nicht umgesetzt, weil sie außerhalb des Prototyps liegen.

5 Umsetzung des Prototyps

Kapitel 5 beschreibt die Umsetzung des in Kapitel 4 entwickelten Konzepts. Zunächst werden die eingesetzten Mittel begründet, anschließend das OCR Modul, danach Matching und Oberfläche. Quelltext wird nicht abgedruckt. Maßgeblich für Kapitel 6 ist die Desktop-Anwendung als Gesamtsystem.

5.1 Verwendete Technologien

Die Umsetzung erfolgt in Python. Textextraktion, Datenbankzugriff und lokaler Server liegen damit in einer Sprache. Eine separate C#-Anwendung allein aufgrund der Windows-Vorgabe würde eine zweite Implementierung derselben Fachlogik erfordern. Stattdessen startet unter Windows dieselbe Logik in einem Desktop-Fenster. Die Pakete `extraction`, `matching` und `app` entsprechen den drei Verantwortlichkeiten aus Abschnitt 4.2, gemeinsame Objekte – insbesondere Eingangsdokument und Laufzeiteinstellungen – sind im Paket `domain` gebündelt. Zwei Kommandozeilenprogramme prüfen Extraktion und Matching ohne Fenster; sie dienen der Entwicklung und der Messung in Kapitel 6, nehmen aber keine Bestätigungen vor.

Die Auftragsdaten stammen aus einer Entwicklungsdatenbank (Supabase auf PostgreSQL-Basis), die über HTTPS angesprochen wird. Dort liegen die nachgestellten Sendungs- und Adresstabellen sowie die eigenen Tabellen des Prototyps. Zugangsdaten stehen in einer lokalen Umgebungsdatei, nicht im Quelltext. Der Produktivserver von Spedifix wird nicht angebunden. Die Fachlogik arbeitet dennoch gegen die Feldnamen des Vorsystems (ErfNr, Storno, Name1, Art). Fehlt die Verbindung, bricht die Anwendung nicht ab: Matching und Auftragslisten zeigen einen Hinweis, die übrige Oberfläche bleibt nutzbar.

Für ausgehende HTTPS-Verbindungen wird der Zertifikatspeicher des Betriebssystems verwendet, da Verbindungen hinter Hochschul- oder Firmenproxies sonst an unvollständigen Zertifikatskatalogen scheitern können. Zugangsdaten erscheinen weder in der Oberfläche noch in Protokollen der Anwendung.

Die Texterkennung stützt sich auf PyMuPDF, Pillow und Tesseract. PyMuPDF liest eingebetteten PDF-Text und rendert Seiten als Bild, wenn OCR erforderlich ist. Pillow öffnet Bilddateien und richtet sie anhand der Aufnahmeorientierung aus. Tesseract übernimmt die Zeichenerkennung und wird über pytesseract angesprochen. Die Engine ist ein getrennt installiertes Programm, kein reines Python-Paket. Unter Windows sucht der Prototyp die üblichen Installationspfade, falls die Engine nicht im Systempfad liegt. Die Sprache ist Deutsch (deu). Die Wahl folgt Abschnitt 3.1: Tesseract ist offen dokumentiert, lizenzfrei nutzbar und hinter einer schmalen Schnittstelle austauschbar. Ein kommerzielles OCR Produkt mit fest eingebauter Formularlogik würde Erkennung und Lizenz in derselben Komponente bündeln.

Die Oberfläche nutzt pywebview und Jinja2. Beim Start wird ein HTTP-Server ausschließlich an 127.0.0.1 gebunden. Ein Fenster lädt diese Adresse; unter Windows kommt die Edge-WebView zum Einsatz. Von anderen Rechnern ist der Server nicht erreichbar. Auf ein clientseitiges Framework wie React wird verzichtet. JavaScript beschränkt sich auf Dateiupload und Auftragssuche. Die Seiten sind dokumentartig gestaltet, die Anwendung bleibt ein lokales Desktop-Programm.

Laufzeitwerte wie Sammelordner, Zeichenschwelle für den Wechsel zur OCR und OCR Sprache stehen in der Umgebungsdatei. OCR und Matching lassen sich zusätzlich in den Einstellungen schalten; ein abweichender Ordnerpfad ebenso. Die Erkennungslabels liegen in einer lokalen Datei. Konfiguration und Quelltext bleiben damit getrennt.

Tabelle 3: Eingesetzte Mittel (Quelle: eigene Darstellung)

Mittel	Rolle im Prototyp
Python	Extraktion, Matching, lokaler Server
PyMuPDF	eingebetteter PDF-Text, Rendern der Seiten für OCR
Tesseract / pytesseract	Zeichenerkennung, Sprache Deutsch
Pillow	Bilddateien öffnen und ausrichten
Supabase-Client	Sendungen lesen, eigene Tabellen schreiben
pywebview	Desktop-Fenster (Windows: Edge-WebView)
Jinja2	serverseitige HTML-Seiten
python-dotenv / truststore	lokale Einstellungen, Systemzertifikate

Nicht Bestandteil der Abgabe sind FastAPI, React, RapidFuzz und eine direkte Verbindung zu Microsoft SQL Server. Unscharfes Matching wurde in Kapitel 3 verworfen. Die produktive Spedifix-Datenbank liegt außerhalb des Studienrahmens.

Kommandozeile und Fenster nutzen dieselbe Fachlogik. Eine in der Konsole erkannte Nummer und ein dort berechneter Score müssen mit der Prüfansicht übereinstimmen; die Kommandozeile nimmt dennoch keine Bestätigungen vor.

Zwei betriebliche Voraussetzungen sind festzuhalten. Eine aktuelle Python-3.10-Version oder neuer ist erforderlich; ältere Systeminstallationen (etwa 3.9) unterstützen die verwendete Syntax nicht. Tesseract und das Sprachpaket „deu“ müssen am Arbeitsplatz installiert sein. Fehlen sie, lässt sich die geforderte Texterkennung nicht durchführen, auch wenn alle Python-Pakete vorliegen.

Die Desktop-Hülle bleibt bewusst schmal. Eine zweite, vollständig native Oberfläche in einer anderen Sprache würde die Fachlogik verdoppeln. Ein öffentlich erreichbarer Dienst käme einer produktiven Schnittstelle sehr nahe und wird daher nicht gewählt. Auf einzelnen Rechnern kann die WebView bei aktiver Grafikkbeschleunigung einfrieren; dies wird über Startparameter der Engine adressiert, nicht durch ein alternatives Oberflächenframework.

Die technische Auswahl bleibt damit bewusst begrenzt: einzelne, austauschbare Bausteine statt einer Plattform, die Texterkennung, Abgleich und Oberfläche in einem Produkt vereint. Für

wechselnde Fremdbelege und Trainingsmaterial wird dieser Aufbau als tragfähig bewertet. Die folgenden Abschnitte beschreiben die konkrete Arbeitsweise der Module.

5.2 Textextraktion und OCR

Die Textextraktion setzt den gestuften Ansatz aus den Abschnitten 3.1 und 4.2 um. Sie prüft zunächst, ob die Datei ein unterstütztes Dokument ist, liest vorhandenen PDF-Text und greift nur bei Bedarf auf die Zeichenerkennung zurück. Die Auftragsnummer wird erst gesucht, wenn Text vorliegt. Das Modul schreibt keine Zuordnung und kennt keine Ampel.

Zulässig sind PDF sowie die Bildformate PNG, JPEG, WebP und TIFF. Die Aufgabenstellung nennt PDF, JPEG und PNG; WebP und TIFF wurden ergänzt, weil sie in der Scan- und Fotopraxis vorkommen und denselben OCR Weg nutzen. Dateien mit anderen Endungen werden bereits vor dem Öffnen eines Parsers zurückgewiesen. Beim Upload erfolgt zusätzlich eine inhaltliche Prüfung: PDF-Dateien müssen mindestens eine Seite enthalten, Bilddateien müssen sich als Bild öffnen lassen. Leere Dateien und Uploads über 25 Megabyte werden abgelehnt. Die Formatanforderung wird damit nicht auf die Dateiendung reduziert.

Der Sammelordner wird rekursiv durchsucht, einschließlich Unterordnern. Die Extraktion arbeitet ausschließlich lesend; Verschieben und Löschen sind der Oberfläche vorbehalten und an eine Pfadprüfung gebunden. Fehlt der Ordner, erscheint eine Fehlermeldung statt einer leeren Erfolgsliste. Beim Upload wird geprüft, ob bereits eine Datei gleichen Namens oder gleichen Inhalts vorhanden ist. Eine zweite Kopie wird nicht angelegt, damit derselbe Beleg nicht zweimal in der Warteschlange erscheint.

Für PDF-Dateien liest PyMuPDF den eingebetteten Text aller Seiten. Der Rohtext wird zeilenweise bereinigt: Mehrfache Leerzeichen werden zusammengezogen, leere Zeilen entfernt. Dadurch lässt sich später der Adressvergleich genauer durchführen, weil ein Zeilenumbruch in der Anschrift sonst dasselbe Merkmal in mehrere Teile aufsplitten würde.

Unterschreitet die Länge dieses Textes eine Schwelle, gilt er als unzureichend. Im Standard beträgt die Schwelle 40 Zeichen. Dieser Wert ist eine Betriebsgröße, keine empirisch bestimmte Konstante. Ein einzelnes Wort oder eine Seitenzahl auf einer sonst gerasterten Seite soll die OCR nicht unterdrücken, ein digitaler Frachtbrief mit mehreren hundert Zeichen soll sie nicht auslösen. Die Schwelle steht in der Laufzeitkonfiguration. Bilddateien besitzen keinen eingebetteten Text und gehen unmittelbar in die Zeichenerkennung. Digitales Lesen und OCR sind damit zu einer Pipeline verbunden, nicht in zwei getrennte Programme aufgespalten.

Die Reihenfolge folgt einem fachlichen Grund. Digital erzeugte PDF-Dateien enthalten Zeichen bereits als Textobjekte. Eine erneute Zeichenerkennung kostet Zeit und kann die Qualität des Textes verschlechtern. Scans und Fotos enthalten diese Objekte nicht; ohne den zweiten Zweig wären sie für Anforderung Nr. 3 (Text, siehe Tabelle 1) unsichtbar.

Die OCR nutzt Tesseract in der Sprache deutsch. PDF-Seiten werden vorab als Bild mit zweifacher linearer Vergrößerung gerendert. Klein gedruckte Schrift wird dadurch besser lesbar, die Laufzeit steigt jedoch mit der Seitenzahl. Fotos werden in einen einheitlichen Farbraum überführt. Enthalten die Bildmetadaten eine Orientierung, wird das Bild vor der

Erkennung gedreht. Unter Windows sucht der Prototyp die Engine in den üblichen Installationsverzeichnissen, falls sie nicht im Systempfad liegt. Schlägt die OCR fehl, bleibt das Eingangsdokument erhalten; der Fehler wird als Hinweis am Beleg vermerkt, der übrige Ordnerlauf wird nicht abgebrochen.

In den Einstellungen kann OCR abgeschaltet werden. Dann entfällt der Fallback: Digitale PDF-Dateien werden weitergelesen, Bilddateien bleiben ohne Text. Diese Stellung ist für Tests und Arbeitsplätze ohne installierte Engine vorgesehen, nicht für den Regelbetrieb gemäß Anforderung Nr. 3 (Text).

Die Auftragsnummer wird nicht als beliebige Zahl gesucht. Aus einer lokal gespeicherten Liste von Bezeichnungen entsteht ein Suchmuster. Zur Voreinstellung gehören unter anderem Erfassungsnummer, ErfNr, Auftragsnummer, Auftrags-Nr. und Auftrag. Längere Bezeichnungen werden zuerst geprüft, damit „Auftragsnummer“ nicht bereits bei „Auftrag“ endet. Zwischen den Wortteilen sind Leerzeichen, Punkte und Bindestriche zulässig. Hinter dem Label darf eine drei- bis sechsstellige Zahl stehen. Folgt unmittelbar eine weitere Ziffer, gilt der Treffer nicht; aus 30015 darf nicht 3001 werden. Andere Zahlen im Beleg – etwa Postleitzahlen, Mengen oder eine Rechnungsnummer ohne passendes Label – bleiben unberücksichtigt.

Fehlt jedes Label, bleibt die erkannte Nummer leer. Ein Rückfall auf die erste Ziffernfolge im Dokument ist nicht implementiert. Dies entspricht der in Abschnitt 3.2 begründeten Ablehnung eines allgemeinen Nummernfinders. Die Liste liegt in einer lokalen Datei, umfasst höchstens 40 Einträge und ist über die Einstellungen änderbar. Eine leere Liste wird nicht gespeichert.

Das Ergebnis des Moduls ist das Eingangsdokument aus Abschnitt 4.3: Pfad, Volltext, optionale Auftragsnummer, Kennzeichen für genutzte OCR und kurze Ablaufhinweise. Diese Hinweise treffen keine fachliche Bewertung des Belegs. Sie halten fest, welcher Zweig der Pipeline gewählt wurde, wie viele Zeichen gelesen wurden und ob eine Nummer gefunden wurde. In der Prüfung erklären sie, warum ein Scan anders behandelt wurde als das Digitaloriginal.

Am Dateipaar `frachtbrief_3001.pdf` und `frachtbrief_3001_scan.pdf` wird der Ablauf exemplarisch sichtbar. Beim Digitaloriginal liefert PyMuPDF ausreichend Text, OCR unterbleibt, und das Label steht vor der Zahl 3001. Beim Scan ist der direkte Text leer. Die Pipeline wählt OCR, Tesseract liefert den Drucktext, und dasselbe Label führt zur selben Zahl. Ist das Scanbild schlecht und zerbricht das Label, bleibt die Nummer leer, obwohl sie für eine Person noch lesbar wäre. Die Oberfläche darf in diesem Fall keinen Wert schätzen oder ergänzen.

Ein zweites Beispiel betrifft Rechnungen. Steht im Kopf „RE-88421“ und im Text „Auftragsnummer: 3006“, darf nur 3006 extrahiert werden. Das Muster erzwingt das Label. Würde die auffälligste Zahl gewählt, läge die Rechnungsnummer vorne und es würde ein falscher Auftrag vorgeschlagen.

Zwei Grenzen gehören zum Modul. Handschrift wird nicht gesondert vorbehandelt. Tesseract arbeitet auf dem gerasterten Bild; eine Offline-Handschrifterkennung im Sinne von Plamondon

und Srihari ist nicht implementiert. Gedruckter Text auf einem Aufkleber durchläuft dieselbe Engine; ob er erkannt wird, hängt von Kontrast, Auflösung und vom Vorhandensein eines Labels ab. Die Beschränkung auf drei bis sechs Ziffern deckt den Demonstrationsnummernkreis, nicht den vom Praxispartner genannten Bereich bis 999.999.999. Dieser Anpassungsbedarf wird in Kapitel 6 festgehalten.

Kommandozeile (`run_extraction.py`) und Import über die Übersicht nutzen dieselbe Pipeline (siehe Abschnitt 5.1)

Absender und Empfänger werden vom Modul nicht als Felder aus dem Text extrahiert. Sie liegen in den Stammdaten und werden erst im Matching im Belegtext gesucht. Die Textextraktion endet beim Eingangsdokument; Suche, Score und Bestätigung liegen außerhalb seines Verantwortungsbereichs.

5.3 Matching Verfahren

Das Matching Modul ist dafür verantwortlich das zentrale Ziel des Projekts umzusetzen, indem es einen möglichst passenden Auftrag zu einem eingehenden Dokument ermittelt und dem Benutzer anschließend einen entsprechenden Zuordnungsvorschlag liefert. Dafür nutzt es als Input die Ergebnisse der zuvor durchgeführten Dokumentenextraktion (siehe Abschnitt 5.2), welche im Matching Modul mit den Auftragsdaten aus der Datenbank abgeglichen werden.

5.3.1 Kandidatensuche

Die Ergebnisse der Informationsextraktion werden im Objekt `IncomingDocument` gespeichert, welches unter anderem die erkannte Auftragsnummer den extrahierte Dokumenttext enthält. Auf Implementierungsebene wurde für den Zugriff auf die Aufträge in der Datenbank eine Repository Klasse angelegt, welche den entsprechenden Datenbankzugriff von der eigentlichen Matching Logik trennt. Über diese Klasse erfolgt die Kandidatensuche sowie die Aufbereitung der relevanten Daten, während die Bewertung des gefundenen Kandidaten durch das zentrale Matching Modul (`matcher.py`) geschieht. Grundsätzlich stellt die Auftragsnummer die zentrale Information für das Matching dar. Diese ist für jeden Auftrag stets eindeutig und daher jeweils nur einmal in der Datenbank hinterlegt. Die ErfNr ist damit als Primärschlüssel für die Tabelle `3100_Sdg_Haupt` definiert. Folglich geschieht die Kandidatensuche hauptsächlich über diese Tabelle, da hier der gesamte Auftragskopf aufzufinden ist. Durch diese Eigenschaft wird im Zuge der Kandidatensuche nicht der gesamte Datenbestand abgeglichen, sodass die Menge der zu überprüfenden Datensätze enorm reduziert wird, was folglich den Rechenaufwand minimiert. Diese Vorgehensweise hat Parallelen zu der in Abschnitt 3.3 genannten Blocking Strategie (vgl. Karr et al. 2019, S.3). Eine weitere Eingrenzung der Datensätze wird dadurch gewährleistet, dass für die zentrale Suche nur die Aufträge berücksichtigt werden, die noch nicht storniert wurden. Mit Blick auf den Abschnitt 3.3 baut das Matching Verfahren dieses Projekts auf einen exakten String Vergleich auf (vgl. Hakak et al. 2019, S.69615 ff.). Eine Fuzzy Matching Strategie wäre hier nicht sinnvoll, da die Merkmale eindeutig übereinstimmen müssen. So würde eine alleinige Ähnlichkeit einer Auftragsnummer zu vielen fehlerhaften

Vorschlägen führen. Falls zu der extrahierten Auftragsnummer ein passender Datenbankeintrag gefunden wird, wird der entsprechende Kandidat in einem Candidate Objekt abgespeichert. Ist diese Auftragsnummer in der Datenbank nicht zu finden, wird kein Zuordnungsvorschlag über andere Kriterien ermittelt. In diesem Fall wird eine manuelle Prüfung empfohlen. Bei einer fehlenden ErfNr im extrahierten Dokumenttext ist hingegen ein Fallback festgelegt worden. In diesem Fall wird über die Firmennamen (Name1) aus der Tabelle 3100_Sdg_Adressen versucht einen passenden Eintrag im extrahierten Dokumenttext zu identifizieren. Vor diesem Abgleich werden die Textwerte jedoch vorab nochmal normalisiert, wodurch beispielsweise Groß- und Kleinschreibung vereinheitlicht und überflüssige Leerzeichen entfernt werden. Damit wird der Abgleich nochmal vergleichbarer. Auf diese Weise kann über die Firmennamensuche ein potenzieller Zuordnungsvorschlag trotz fehlender Auftragsnummer ermittelt werden.

5.3.2 Kandidatenbewertung

Erst wenn in einem der beiden Fälle ein passender Eintrag gefunden wurde, kann eine Kandidatenbewertung stattfinden. Diese anschließende Bewertung erfolgt anhand mehrerer Merkmale und einer Confidence Score Berechnung zum Schluss. Nicht alle Attribute in der Tabelle besitzen die gleiche Aussagekraft für die Zuordnung eines Dokuments, weshalb drei zentrale Merkmale selektiert und entsprechend gewichtet wurden (siehe Tabelle 4). Die beiden weiteren bewerteten Merkmale neben der Auftragsnummer sind der Absender und Empfänger. Für den Abgleich einer Adresse werden die in der Datenbank vorhandenen Felder Name, Strasse, Plz und Ort (3100_Sdg_Adressen) betrachtet. Ein Absender bzw. Empfänger gilt nur dann als übereinstimmend, wenn alle vier Einträge vollständig im extrahierten Dokumenttext aufgefunden wurden. Damit werden partielle Übereinstimmungen vorgebeugt.

Tabelle 4: Gewichtung der Merkmale für die Kandidatenbewertung

Merkmals	Gewicht
Auftragsnummer	0,6
Absender	0,2
Empfänger	0,2

Der Gesamtscore ergibt sich als gewichtete Summe der Merkmale. Anhand der Tabelle 4 ist zu erkennen, dass der resultierende Gesamtscore stets im Intervall $[0,1]$ liegt. Eine weitere wichtige Eigenschaft ist, dass die einzelnen Merkmale binär bewertet werden. Ein Merkmal erhält somit entweder eine 1 für eine vollständige Übereinstimmung oder eine 0. Damit wurde bewusst eine Bewertung im Intervall $[0,1]$ vermieden, da die geprüften Informationen exakt übereinstimmen sollen und nicht partiell.

Tabelle 4 zeigt zudem, dass die Auftragsnummer mit 0,6 das höchste Gewicht besitzt. Dies ergibt sich daraus, dass die ErfNr eine höhere Aussagekraft besitzt als die einzelnen Adressinformationen, die im realen Unternehmensprozess auch mehreren Aufträgen zugehörig sein könnten. Gleichzeitig wurde die Auftragsnummer nicht stärker gewichtet, da vorab auch OCR Erkennungsfehler (siehe Abschnitt 3.1) möglich sind. Wird beispielsweise eine

fehlerhafte, aber zufällig in der Datenbank vorhandene Auftragsnummer erkannt, könnte eine zu hohe Gewichtung zu einem fehlerhaften Zuordnungsvorschlag führen, der dann letztlich einen sehr hohen Score erhält. Die Gewichtung 0,6 stellt daher einen Kompromiss dar. Die Schwelle für eine hohe Übereinstimmung liegt standardmäßig bei 0,8. Werte ab 0,60 werden als mittel eingestuft und darunterliegende Scores sind als niedrig zu bewerten. Anhand von Tabelle 4 wird damit deutlich, dass ein Score von 1 und damit eine vollständige Übereinstimmung möglich ist. Dennoch ist hier zu beachten, dass dieser Score keine garantierte Zugehörigkeit des ursprünglichen Eingangsdokuments zu einem Auftrag impliziert. Ein solcher Idealfall beschreibt lediglich, dass das Ergebnis der Informationsextraktion mit den Auftragsdaten in der Datenbank vollständig abgeglichen werden konnte.

Außerdem kann anhand der Tabelle erkannt werden, dass die beiden Merkmale Absender und Empfänger in der Summe mit 0,4 nicht ausreichen, um einen Zuordnungsvorschlag zu generieren. Daher kann bei einem Fallback im Idealfall nur ein Score von maximal 0,4 erreicht werden. Nach der manuellen Bestätigung werden die relevanten Ergebnisse wie z.B. die erkannte ErfNr und der berechnete Score in der Tabelle DokumentZuordnung gespeichert. Durch diese Archivierung wird verhindert, dass ein bereits verarbeitetes Dokument bei späteren Zugriffen erneut durch OCR und Matching bearbeitet wird. Diese Bestätigung kann dabei widerrufen werden, was die Zuordnung löscht und damit die Extraktion und das Matching erneut durchlaufen lässt.

Insgesamt besteht das Matching Modul somit aus zwei grundlegenden Aufgaben, wobei zunächst ein Zuordnungsvorschlag ermittelt werden soll. Im anschließenden Schritt wird der Vorschlag anhand von zusätzlichen Merkmalen bewertet. Das Ergebnis ist dann ein begründeter Zuordnungsvorschlag mit einem Confidence Score. So wie es auch im Abschnitt 2.2 definiert ist, kommt es in keinem Fall zu einer automatischen Zuordnung durch die Applikation, um fehlerhafte Archivierungen vorzubeugen. Vielmehr bleibt eine manuelle Bestätigung durch einen Mitarbeiter zwingend erforderlich, wodurch hier auch der hybride Ansatz von Mensch und Maschine an dieser Stelle eingebaut wurde (siehe Abschnitt 3.3).

5.4 Benutzeroberfläche

Die Oberfläche von SmartAssign ist in fünf Bereiche gegliedert, die über eine seitliche Navigationsleiste erreichbar sind: Übersicht, Zuordnung, Aufträge, Auswertungen und Einstellungen. Die Seiten werden lokal als HTML ausgeliefert. pywebview stellt das Fenster bereit. Clientseitige Logik bleibt auf den Dateimport und die Auftragssuche beschränkt.




Abbildung 3: Übersicht von SmartAssign (Quelle: eigene Darstellung)

Nach dem Start öffnet sich die Übersichtsseite. Sie zeigt den Bestand der importierten Belege. Im Kopf stehen vier Kennzahlen: die Zahl der Dokumente, die Zahl der bestätigten Zuordnungen, die Zahl der Belege mit ausstehender Prüfung und die Zahl der Belege ohne passenden Auftrag. Darunter liegt der Importbereich. Dateien können über die Dateiauswahl, per Drag-and-Drop oder als Ordner übernommen werden. Im unteren Teil stehen eine verkürzte Liste offener Zuordnungen und eine Chronik zuletzt gespeicherter Schritte, etwa Import und Bestätigung.

Unter Zuordnung werden die importierten Dokumente tabellarisch angezeigt. Die Listenansicht ist in Abbildung 4 dargestellt.

SmartAssign

Übersicht

Zuordnung

Aufträge

Auswertungen

Einstellungen

Dokumentenzuordnung

Offene und bestätigte Belege Aufträgen zuordnen.

Dokumente

Zugeordnet

Prüfung erforderlich

Keine Zuordnung

Dokument, Lieferant oder Auftrag suchen

28.08.2026

bis

28.08.2026

Filtern

Zuordnung erneut ausführen

8 offene Prüfungen

DOKUMENT	Lieferant / Kunde	AUFTRAG	STATUS	SICHERHEIT	EINGANGSDATUM ▼	Aktionen
Invoice_3006.pdf	-	-	Keine Zuordnung	Kein Kandidat	28.08.2026	Prüfen Löschen
wareneingang_8888.pdf	-	-	Keine Zuordnung	Kein Kandidat	28.08.2026	Prüfen Löschen
schadensmeldung_ohne_nummer_nur...	-	3001	Prüfung erforderlich	Niedrig - 20%	28.08.2026	Prüfen Löschen
schadensmeldung_ohne_nummer.pdf	-	3002	Prüfung erforderlich	Niedrig - 40%	28.08.2026	Prüfen Löschen
lieferschein_3002_ohne_adressen.pdf	-	3002	Prüfung erforderlich	Mittel - 60%	28.08.2026	Prüfen Löschen
lieferschein_3001_nur_absender.pdf	-	3001	Prüfung erforderlich	Hoch - 80%	28.08.2026	Prüfen Löschen
Invoice_3004.pdf	-	3004	Prüfung erforderlich	Hoch - 100%	28.08.2026	Prüfen Löschen
frachtbrief_3001_scan.pdf	-	3001	Prüfung erforderlich	Hoch - 100%	28.08.2026	Prüfen Löschen
wareneingang_3005.pdf	AlpenLogistik GmbH	3005	Bestätigt	Bestätigt 100%	28.08.2026	Bearbeiten Löschen
schadensmeldung_3003.pdf	Harz Spedition Goslar	3003	Bestätigt	Bestätigt 100%	28.08.2026	Bearbeiten Löschen
lieferschein_3002.pdf	Weser Cargo GmbH	3002	Bestätigt	Bestätigt 100%	28.08.2026	Bearbeiten Löschen
Invoice_3004_scan.pdf	Nordholz Spedition GmbH	3004	Bestätigt	Bestätigt 100%	28.08.2026	Bearbeiten Löschen
frachtbrief_3001.pdf	Nordholz Spedition GmbH	3001	Bestätigt	Bestätigt 100%	28.08.2026	Bearbeiten Löschen

Abbildung 4: Zuordnungsübersicht in SmartAssign (Quelle: eigene Darstellung)

Je Zeile sind Dateiname, Eingangsdatum, vorgeschlagener Auftrag, Status und Sicherheitsklasse sichtbar. Der Status lautet Bestätigt, Prüfung erforderlich oder Keine Zuordnung. Daneben können Fehlerhaft, In Bearbeitung und Matching deaktiviert erscheinen. Die Sicherheitsanzeige unterscheidet Hoch, Mittel, Niedrig und Kein Kandidat. Sie ist eine Darstellungsklasse, keine Freigabe. Oben wird die Zahl der offenen Prüfungen eingeblendet. Gefiltert werden Status, Suche und Eingangsdatum, nicht das Belegdatum. Prüfen öffnet die Detailansicht. Löschen entfernt den Eintrag. Bei bereits bestätigten Zeilen heißt die Aktion Bearbeiten.

In der Detailansicht werden der Beleg, der vorgeschlagene Auftrag und die drei Merkmalszeilen Auftragsnummer, Absender und Empfänger gezeigt. Der Nutzer kann den Vorschlag bestätigen, einen anderen Auftrag zuordnen oder die Zuordnung offenlassen. Gespeichert wird erst nach Bestätigung. Eine nicht bestätigte Zuordnung wird nicht übernommen.

Die Auftragsseite ist in Abbildung 5 dargestellt.

SmartAssign

Übersicht

Zuordnung

Aufträge

Auswertungen

Einstellungen

Aufträge

Aufträge und zugehörige Dokumente.

Auftragsnummer, Kunde oder Beschreibu...

Alle Status

28.08.2026

bis

28.08.2026

Alle Kunden

Filtern

AUFTRAGSNUMMER	KUNDE	Beschreibung	STATUS	DOKUMENTE	ERSTELLT	Aktion
3005	AlpenLogistik GmbH	REF05	Vollständig	1	2026-08-20	Details
3003	Harz Spedition Goslar	FB-3003	Vollständig	1	2026-08-19	Details
3004	Nordholz Spedition GmbH	REF04	Prüfung erforderlich	2	2026-08-19	Details
3001	Nordholz Spedition GmbH	FB-3001	Prüfung erforderlich	4	2026-08-18	Details
3002	Weser Cargo GmbH	FB-3002	Prüfung erforderlich	3	2026-08-18	Details
2908	Münsterland Transport GmbH	REF-2908	Ohne Dokumente	0	2026-08-15	Details
2907	Lüneburger Heide Spedition	REF-2907	Ohne Dokumente	0	2026-08-08	Details
2906	Saarländ Cargo Saarbrücken AG	REF-2906	Ohne Dokumente	0	2026-08-01	Details
2905	Ruhr Express Dortmund GmbH	REF-2905	Ohne Dokumente	0	2026-07-22	Details
2904	Schwarzwald Freight Freiburg	REF-2904	Ohne Dokumente	0	2026-07-14	Details
2903	Mainfranken Logistics Würzburg	REF-2903	Ohne Dokumente	0	2026-07-03	Details
2902	Weser Transport Bremen AG	REF-2902	Ohne Dokumente	0	2026-06-25	Details
2901	Rhein Cargo Köln GmbH	REF-2901	Ohne Dokumente	0	2026-06-12	Details

Abbildung 5: Auftragsübersicht in SmartAssign (Quelle: eigene Darstellung)

Die Auftragsseite listet die Sendungen der nachgestellten Auftragsdatenbank. Je Zeile erscheinen Erfassungsnummer, Kundenname, Bearbeitungsstand und die Zahl zugeordneter Dokumente. Der Stand unterscheidet Vollständig, Prüfung erforderlich und Ohne Dokumente. Filter betreffen Status, Erstellungsdatum und Kunde. Über Details sind Stammdaten und zugeordnete Belege sichtbar. Die Aufträge sind in SmartAssign nur lesbar. Es wird nicht in das produktive Vorsystem geschrieben.




Abbildung 6: Auswertungsseite in SmartAssign (Quelle: eigene Darstellung)

Die Auswertungsseite fasst den bearbeiteten Bestand zusammen. Oben stehen dieselben vier Kennzahlen wie auf der Übersicht, bezogen auf den gewählten Zeitraum. Darunter liegt die Verteilung der Sicherheitsklassen: Hoch ab 0,80, Mittel ab 0,60, Niedrig darunter. Die Klassen beschreiben die Anzeige, nicht eine gemessene Trefferquote. Ein Verlauf zeigt den Anteil bestätigter Zuordnungen. Der Zeitraum ist fest vorgegeben, etwa die letzten 30 Tage.




Abbildung 7: Einstellungsseite von SmartAssign (Quelle: eigene Darstellung)

Die Einstellungen gliedern sich in Datenquellen, Verarbeitung und Labels. Unter Datenquellen sind manueller Upload, Importordner und Auftragsdatenbank einsehbar. Der Ordnerpfad kann gesetzt werden. Eine Verbindungsprüfung prüft die Erreichbarkeit der Tabellen. Das System überwacht den Ordner nicht dauerhaft. Er wird beim Start, nach einem Import und bei einem erneuten Durchlauf gelesen. Unter Verarbeitung lassen sich OCR als Rückfall und das automatische Matching ein- und ausschalten. Unter Labels werden die Bezeichnungen gepflegt, hinter denen die Auftragsnummer gesucht wird. Die Liste liegt lokal.

6 Evaluation

Kapitel 6 bewertet, inwieweit der entwickelte Prototyp die in Abschnitt 2.3 definierten Anforderungsziele erreicht. Nach der Darlegung des Untersuchungsdesigns und der Testdaten wird der Prototyp anhand dieser Kriterien evaluiert. Den Abschluss bilden die methodischen Grenzen sowie Überlegungen zur Übertragbarkeit auf den laufenden Betrieb.

Da keine Testdaten aus dem laufenden Spedifix-Betrieb zur Verfügung stand, wurde ein synthetischer Testdatenbestand aus insgesamt 12 Dateien aufgebaut. Die Digitaloriginale wurden mittels Online-Rechnungsgeneratoren sowie generativer KI für abweichende Layouts erzeugt.

Als funktionale Basis dienen die Erfassungsnummern 3001 bis 3006 mit vollständigen Absender- und Empfängerdaten. Der Satz umfasst fiktive Frachtbriefe, Lieferscheine, Schadensmeldungen, Wareneingänge und Rechnungen. Zu den Belegen 3001 und 3004 existiert zusätzlich jeweils eine reine Scan-Version ohne eingebetteten Text; Rechnung 3006 besitzt kein Scan-Pendant. Über den identischen Wortlaut von Digitaloriginal und Scan wird geprüft, ob der digitale Textpfad und der OCR-Pfad dieselbe Erfassungsnummer extrahieren.

Die Dokumente sind gut lesbar gestaltet (deutliche Labels, vierstellige Nummern). Die Scans stellen saubere Rasterisierungen der Digitaloriginale dar, ohne Verunreinigungen oder Rotationsfehler. Damit wird primär der Umschaltmechanismus der Erkennungspipeline evaluiert, nicht die Güte der Zeichenerkennung unter realen Bedingungen des papiergestützten Büroalltags.

6.1 Untersuchungsdesign und Testdaten

Tabelle 5: Textdateien (Quelle: eigene Darstellung)

Datei	Art	Nummer	Textweg	Vorgesehen
frachtbrief_3001.pdf	Frachtbrief	3001	Text	Nummer + Adressen
frachtbrief_3001_scan.pdf	Frachtbrief	3001	OCR	wie oben
lieferschein_3002.pdf	Lieferschein	3002	Text	Nummer + Adressen
lieferschein_3002_ohne_adressen.pdf	Lieferschien	3002	Text	nur Nummer
schadensmeldung_3003.pdf	Schadensmeldung	3003	Text	Nummer + Adressen
Invoice_3004.pdf	Rechnung	3004	Text	Nummer + Adressen
Invoice_3004_scan.pdf	Rechnung	3004	OCR	wie oben
wareneingang_3005.pdf	Wareneingang	3005	Text	Nummer + Adressen
Invoice_3006.pdf	Rechnung	3006	Text	Label, nicht RE -88421
lieferschein_3001_nur_absender.pdf	Lieferschein	3001	Text	Nummer + Absender
schadensmeldung_ohne_nummer.pdf	Schadensmeldung	3001	Text	Keine Nummer, Adressen 3002
wareneingang_8888.pdf	Wareneingang	8888	Text	Kein Auftrag in DB

Die Datenbank-Gegenstücke liegen in der Entwicklungsdatenbank vor. In den Tabellen 3100_Sdg_Haupt und 3100_Sdg_Adressen wurden Sendungen zu den Nummern 3001 bis 3006 inklusive Absender (Art 1) und Empfänger (Art 2) angelegt. Stornierte Datensätze oder der Eintrag 8888 wurden nicht angelegt. Ein Abzug der produktiven Spedifix-Datenbank wurde nicht verwendet.

Die Extraktion wurde über die Kommandozeile der Pipeline gemessen (Sprache Deutsch, OCR-Fallback unterhalb von 40 Zeichen Direkttext). Da die Soll-Nummern manuell in die Testdateien integriert wurden, stehen die Erwartungswerte vorab fest. Eine unabhängige Zweitkodierung entfällt.

Matching-Quoten werden nicht als statistische Prozentreihe berichtet, da hierfür ein reproduzierbarer Massentestlauf fehlt. Aus dem Versuchsaufbau ergeben sich Soll-Erwartungen: Digitaloriginal und Scan müssen dieselbe Nummer liefern. Ist die Nummer in der

Datenbank hinterlegt und passen beide Adressen, erreicht der Score 1,00; fehlt eine Adresse, maximal 0,80. Fehlt das Ziffernlabel vollständig, darf kein Wert geraten werden. Dies prüft die Regellogik aus Kapitel 5, ersetzt jedoch keine empirisch ermittelte Trefferquote.

Zeichenfehlerraten und Bearbeitungszeiten der Sachbearbeitung wurden nicht erhoben. Die Gewichte 0,6 / 0,2 / 0,2 sowie die Ampelschwellen 0,60 / 0,80 entsprechen den Festlegungen aus Kapitel 4 und wurden nicht nachträglich an die Testdaten angepasst.

6.2 Erfüllung der Anforderung

Die Bewertung orientiert sich an den Zielen aus Abschnitt 2.3 und am Stand aus Kapitel 5. Die einzelnen Anforderungen sind dort bereits tabellarisch festgehalten; sie werden hier nicht zeilenweise wiederholt. „Erfüllt“ bedeutet, dass das geforderte Verhalten im Prototyp nachweisbar ist, nicht, dass dieselbe Leistung im produktiven Spedifix-Betrieb belegt ist.

Umgesetzt sind die Entgegennahme von PDF- und Bilddateien, die Bereitstellung als Windows-fähige Desktop-Anwendung sowie der Import über Sammelordner und Upload. Digitaler Textimport und OCR für Bilddokumente sind in einer Pipeline zusammengeführt. Der Dateibestand in Abschnitt 6.1 erlaubt die getrennte Auslösung beider Pfade. Auftragsnummern werden ausschließlich hinter konfigurierbaren Labels erkannt. Ein Rückfall auf beliebige Zahlenketten ist nicht implementiert.

Sofern die Entwicklungsdatenbank erreichbar ist, wird ein Zuordnungsvorschlag erzeugt. Die Suche erfolgt primär über die Erfassungsnummer, sekundär über den Namensfilter. Ein Nachweis gegen die produktive Spedifix-Datenbank steht aus. Der manuellen Prüf- und Bestätigungspflicht wird entsprochen: Der Score führt nicht zu automatischen Schreibvorgängen. Fehlt ein passender Kandidat, bleibt die manuelle Zuordnung möglich. Score, Ampel und die drei Merkmalszeilen machen den Vorschlag in der deutschsprachigen Oberfläche nachvollziehbar.

Die Anforderung an die Verarbeitungszeit wird als teilweise erfüllt bewertet. Einzelbelege werden in zumutbarer Zeit verarbeitet. Eine Lastmessung mit mehreren Dokumenten pro Auftrag fehlt. Ein betrieblicher Zeitgewinn gegenüber dem Ist-Prozess ist nicht belegt.

Die Zielerfüllung nach Bereichen ist in Tabelle 6 zusammengefasst.

Tabelle 6: Bewertung nach Bereichen (Quelle: eigene Darstellung)

Bereich	Bewertung	Grundlage
Formate, Import, Desktop	Erfüllt	Beobachtetes Verhalten, Dateibestand in 6.1
Extraktion, Vorschlag, Bestätigung	erfüllt im Prototyp	Kapitel 5, Entwicklungsdatenbank
Verarbeitungszeit, Betrieb	Teilweise bzw. nicht belegt	Keine Last- oder Feldmessung

Nicht explizit geforderte Eigenschaften, etwa Handschrifterkennung, produktive MS-SQL-Anbindung oder eine Klassifikation nach Belegtyp, werden nicht als Mangel gewertet.

Formate, OCR-Umschaltung und Label-Erkennung stützen sich auf den Dateibestand. Bestätigung und manuelle Wahl stützen sich auf das in Kapitel 5 beschriebene Speichern und Anzeigen. Ein Feldversuch mit Sachbearbeitung fehlt.

Eine aggregierte Matching-Trefferquote in Prozent wird nicht ausgewiesen. Eine solche Kennzahl würde Extraktion, Regeln und Bestätigung vermengen. Die Aufgabenstellung, die manuelle Zuordnung auf Kontrolle und Bestätigung zu verkürzen, ist im Prototyp nachvollziehbar umgesetzt. Nicht nachgewiesen ist, dass dieselbe Verkürzung im laufenden Belegarchiv von Spedifix eintritt.

6.3 Grenzen und Übertragbarkeit

Die Bewertung in Abschnitt 6.2 gilt für den Studienprototyp und den konstruierten Dateibestand. Eine Übertragung auf den laufenden Belegfluss bei Spedifix ist nur unter Vorbehalt möglich.

Der Testbestand ist layoutgleich und gut lesbar. Digitaloriginale und ihre Scans enthalten dieselben Zahlen und Labels. Verschmutzte Papierbelege, schräg fotografierte Aufnahmen und stark abweichende Fremdlayouts sind nicht enthalten. Aus dem korrekten Zweigwechsel (eingebetteter Text bzw. OCR) folgt deshalb keine allgemeine Aussage über die Güte der Zeichenerkennung im Büroalltag.

Der Matching-Score bleibt grob. Ein einziges abweichendes Adressfeld setzt das gesamte Absender- oder Empfängermerkmal auf null. Das sichert die Nachvollziehbarkeit und senkt die Toleranz gegenüber OCR Vertauschungen in Straßennamen. Die Grenzen 0,60 und 0,80 ergeben sich aus den Gewichten; sie sind festgelegte Konventionen, keine an Felddaten geschätzten Optimalwerte. Ob ein hoher Score fachlich der richtige Auftrag ist, misst Kapitel 6 nicht. Gemessen bzw. geprüft wird, ob ein Vorschlag entsteht, begründet ist und erst nach Bestätigung gespeichert wird.

Die gesuchte Zahl ist auf drei bis sechs Stellen beschränkt. Der vom Praxispartner genannte Nummernkreis reicht bis 999.999.999 (vgl. Fiebach 2026, S. 1). Längere Erfassungsnummern würden mit dem aktuellen Muster nicht erkannt. Für den Demonstrationsbestand mit vierstelligen Nummern ist das unschädlich, für eine Übernahme in den Betrieb ist es eine Anpassungsstelle.

Die Entwicklungsdatenbank bildet Sendungsköpfe und Adressen nach, nicht das vollständige Spedifix-Schema und nicht Microsoft SQL Server. Dateipfade sind lokal. Eine gemeinsame Cloud-Tabelle mit Einträgen anderer Rechner würde Belege zeigen, deren Dateien am jeweiligen Arbeitsplatz fehlen. Die Architektur filtert deshalb auf den lokalen Sammelordner. Die Schreibstrecke in das produktive Belegarchiv fehlt. Der Prototyp endet bei der bestätigten Zuordnung in den eigenen Tabellen.

Der Adress-Fallback lädt Namensfelder und vergleicht sie in der Anwendung. Bei wachsender Auftragsmenge wird dieser Schritt zum Engpass. Für die Testmenge ist er tragbar. Im Dauerbetrieb müsste die Vorauswahl näher an die Datenbank rücken.

Es gibt keine Anmeldung. Wer bestätigt hat, wird nicht festgehalten. Es gibt keine Messung der Bearbeitungszeit gegenüber dem Ist-Prozess. Der Prüfschritt lässt sich vorführen; eingesparte Minuten je Auftrag sind nicht belegt.

Für eine Übernahme durch Spedifix folgen daraus Anpassungsstellen, keine grundsätzliche Absage. Das Ziffernmuster muss den vollen Nummernkreis abdecken. Die Vorauswahl ohne erkannte Nummer muss in der Datenbank erfolgen. Die bestätigte Verknüpfung muss in das bestehende Belegarchiv geschrieben werden, nicht in eine parallele Tabelle. Microsoft SQL Server tritt an die Stelle der Entwicklungsumgebung. Keine dieser Stellen ändert den Soll-Prozess aus Kapitel 4. Sie ändern die technische Abbildung.

Die interne Gültigkeit der Anforderungsprüfung ist hoch, weil die Ziele vor der Bewertung in Kapitel 2 benannt wurden. Die Gültigkeit der Extraktionsaussage ist mittel: Geprüft wird die Übereinstimmung mit dem konstruierten Sollwert, nicht mit einer von der Sachbearbeitung gesetzten Wahrheit auf unbekannten Belegen. Die externe Gültigkeit ist gering. Wer den Prototyp als Nachweis für den laufenden Betrieb liest, überschätzt Abschnitt 6.1. Wer ihn als Nachweis liest, dass die gestellten Studienziele umsetzbar sind, liegt näher an dem, was die Evaluation tragen kann.

7 Fazit und Ausblick

Kapitel 7 beendet die Arbeit in zwei Teilen. Zunächst werden die erarbeiteten Erkenntnisse zusammengefasst. Anschließend werden offene Fragen und Anpassungsstellen benannt, die über den Studienprototyp hinausreichen.

7.1 Rückblick

Nachgelagerte Fremdbelege entstehen im Auftragsdurchlauf, nachdem der Auftrag bereits erfasst ist. Sie erreichen das Unternehmen als PDF, JPEG oder PNG, als Scan, als Anhang oder als Papier. Ein Teil der Unterlagen wird bei der Auftragserfassung erzeugt und automatisch archiviert. Dem anderen Teil fehlt häufig die Verbindung zur fortlaufenden Erfassungsnummer (vgl. Fiebach 2026, S. 1). Im Ist-Prozess wird das Dokument digital bereitgestellt, auf eine Auftragsnummer geprüft und manuell einem vorhandenen Auftrag zugeordnet. Pro Auftrag können dabei zehn bis zwanzig Belege anfallen. Die Zuordnung hängt von der jeweiligen Person ab. Eine Zeitangabe in Minuten je Beleg lag in der Ausgangssituation nicht vor.

Daraus wurden in Abschnitt 2.3 die Maßstäbe für den Prototyp festgehalten. Gefordert waren PDF sowie mindestens JPEG und PNG, die Übernahme bereits digitaler Dateien ohne erneuten Scan, zuerst eingebetteter Text und sonst Zeichenerkennung, die Auftragsnummer nur hinter festgelegten Bezeichnungen, ein begründeter Vorschlag und das Speichern erst nach Bestätigung. Nicht gefordert waren Handschrifterkennung, die produktive Spedifix-Umgebung und das Schreiben ins bestehende Belegarchiv. Der Soll-Prozess gehört nicht in die Anforderungstabelle; er wurde in Kapitel 4 festgelegt.

Die Zielsetzung in Abschnitt 1.2 blieb bewusst schmaler als der Wunsch, den Prozess zu automatisieren. Automatisiert werden Lesen, Suche und Vorschlag. Nicht automatisiert wird die Freigabe. Würde jede Zahl im Beleg als Auftragsnummer gelten, entstünde ein Vorschlag aus dem falschen Feld. Würde ein hoher Score die Zuordnung schreiben, entfielen die Kontrolle. Beides wäre eine andere Arbeit. Erreicht ist das Ziel, wenn sich dieses Verhalten am Studienprototyp nachvollziehen lässt. Erreicht ist es nicht, wenn dieselbe Verkürzung im laufenden Belegarchiv nachgewiesen wäre.

Kapitel 3 hat zwischen Anforderungserhebung und eigener Bearbeitung die Verfahren gesichtet, die Text liefern, Merkmale extrahieren und Beleg mit Auftrag vergleichen. Layoutbasierte Extraktionsmodelle wurden nicht übernommen, weil der Prototyp mit eingebettetem Text und einem OCR-Rückfall auskommt und die Lage einzelner Felder auf der Seite nicht trainiert. Unscharfes Matching wurde nicht übernommen, weil die Begründung zeilenweise nachvollziehbar bleiben sollte. Übernommen wurde die Trennung von Vorauswahl und Bewertung sowie die Pflicht, dass ein Vorschlag erst nach menschlicher Bestätigung gilt. Kapitel 4 und 5 greifen diese Wahl auf. Sie führen keinen zweiten Lösungsweg ein.

Der eigene Ansatz zerlegt die Aufgabe in drei Pakete. Die Extraktion liest den Beleg und sucht die Nummer hinter Labels. Das Matching sucht mit erkannter Nummer über die Erfassungsnummer, ohne Nummer über einen Namensfilter. Schlägt die Suche über eine erkannte Nummer fehl, folgt kein Namensrückfall. Die Bewertung ist exakt und dreiteilig: Auftragsnummer 0,6, Absender- und Empfängeradresse je 0,2. Datum, Referenz und Belegart gehen weder in den Score noch in die Begründung ein. Die Klassen unter 0,60, ab 0,60 und ab 0,80 sind Darstellungskonventionen, keine Freigabe. Die Oberfläche zeigt den Vorschlag; speichern darf nur die Bestätigung. Belegsatz und Zuordnungssatz bleiben getrennt, damit ein Score nicht als Freigabe gelesen werden kann. Technisch ist SmartAssign eine lokale Desktop-Anwendung. Die Auftragsdaten stammen aus einer nachgestellten Entwicklungsdatenbank, nicht aus der produktiven Spedifix-Umgebung.

7.2 Bewertung der Evaluation

Kapitel 6 hält diesen Ansatz an den Zielen aus Abschnitt 2.3. Zwei Verfahren greifen ineinander. Erstens wird das dokumentierte Verhalten gegen die Anforderungen gehalten. Zweitens wird die Nummernextraktion an einem festen Dateibestand gemessen. Testdaten aus dem laufenden Betrieb stand nicht zur Verfügung. Der beigelegte Satz umfasst 12 Dateien: fiktive Frachtbriefe und Rechnungen mit den Erfassungsnummern 3001 bis 3006, darunter zu 3001 bis 3004 jeweils eine Scan-Version ohne eingebetteten Text. Die Dateien sind gut lesbar gesetzt. Geprüft wird der Wechsel in der Erkennungspipeline, nicht die Güte der Zeichenerkennung im Büroalltag. Matching-Anteile gegen die Auftragsdatenbank werden nicht als Prozentreihe berichtet. Dafür fehlt ein Lauf, der sich mit derselben Anbindung nachrechnen lässt.

Formate, Bereitstellung, Textweg, Labelbindung, Vorschlag, Begründung und Bestätigungspflicht sind im Studienprototyp nachvollziehbar. Fehlt ein Kandidat, bleibt die manuelle Auftragswahl möglich. Die Prüfung findet in derselben Anwendung statt. Die

Verarbeitungszeit gilt als teilweise erfüllt. Einzelne Testdateien wurden in zumutbarer Zeit gelesen. Eine Lastmessung mit zehn bis zwanzig Belegen je Auftrag in einer großen Auftragsmenge fehlt. Ein betrieblicher Zeitgewinn gegenüber dem Ist-Prozess ist nicht belegt.

Die interne Gültigkeit der Anforderungsprüfung ist hoch, weil die Ziele vor der Bewertung in Kapitel 2 benannt wurden. Die Gültigkeit der Extraktionsaussage ist mittel: Geprüft wird die Übereinstimmung mit dem konstruierten Sollwert, nicht mit einer von der Sachbearbeitung gesetzten Wahrheit auf unbekannten Belegen. Die externe Gültigkeit ist gering. Wer den Prototyp als Nachweis für den laufenden Betrieb liest, überschätzt Abschnitt 6.1. Wer ihn als Nachweis liest, dass die gestellten Studienziele umsetzbar sind, liegt näher an dem, was die Evaluation tragen kann. Die Aufgabenstellung, die manuelle Zuordnung auf Kontrolle und Bestätigung zu verkürzen, ist im Prototyp nachvollziehbar umgesetzt. Nicht nachgewiesen ist, dass dieselbe Verkürzung im laufenden Belegarchiv von Spedifix eintritt.

7.3 Offene Fragen und Übertragbarkeit

Für eine Übernahme durch den Praxispartner folgen daraus Anpassungsstellen, keine grundsätzliche Absage und keine Änderung des Soll-Prozesses aus Kapitel 4. Sie ändern die technische Abbildung.

Das Ziffernmuster ist auf drei bis sechs Stellen beschränkt. Der vom Praxispartner genannte Nummernkreis reicht bis 999.999.999 (vgl. Fiebach 2026, S. 1). Längere Erfassungsnummern würden mit dem aktuellen Muster nicht erkannt. Für den Demonstrationsbestand mit vierstelligen Nummern ist das unschädlich, für den Betrieb ist es die erste Anpassungsstelle.

Die Vorauswahl ohne erkannte Nummer lädt Namensfelder und vergleicht sie in der Anwendung. Bei wachsender Auftragsmenge wird dieser Schritt zum Engpass. Im Dauerbetrieb müsste die Vorauswahl näher an die Datenbank rücken. Schlägt die Suche über eine erkannte Nummer fehl, bleibt es dabei: Ein Namensrückfall ist nicht vorgesehen und soll auch bei einer Übernahme nicht stillschweigend ergänzt werden.

Die Entwicklungsdatenbank bildet Sendungsköpfe und Adressen nach, nicht das vollständige Schema und nicht Microsoft SQL Server. Dateipfade sind lokal. Die Schreibstrecke in das produktive Belegarchiv fehlt. Der Prototyp endet bei der bestätigten Zuordnung in den eigenen Tabellen. Eine Übernahme müsste die Verknüpfung dorthin schreiben, wo Spedifix die Belege bereits führt.

Es gibt keine Anmeldung. Wer bestätigt hat, wird nicht festgehalten. Es gibt keine Messung der Bearbeitungszeit gegenüber dem Ist-Prozess. Der Prüfschritt lässt sich vorführen; eingesparte Minuten je Auftrag sind nicht belegt. Der Matching-Score bleibt grob: Ein einziges abweichendes Adressfeld setzt das gesamte Absender- oder Empfängermerkmal auf null. Die Grenzen 0,60 und 0,80 ergeben sich aus den Gewichten. Ob ein hoher Score fachlich der richtige Auftrag ist, misst Kapitel 6 nicht.

Offen bleibt außerdem, wie sich Extraktion und Matching auf verschmutzte Papierbelege, schräg aufgenommene Fotos und stark abweichende Fremdlayouts verhalten. Der Dateibestand in Abschnitt 6.1 trägt diese Frage nicht. Eine solche Prüfung setzte Testdaten aus dem laufenden

Betrieb und eine unabhängige Kodierung durch die Sachbearbeitung voraus. Solange beides fehlt, bleibt SmartAssign ein prüfbarer Studienprototyp für Vorschlag und Bestätigung, kein belegter Betriebsnachweis.

Literaturverzeichnis

- Alaei, A., Bui, V., Doermann, D. und Pal, U. (2023): Document Image Quality Assessment: A Survey, *ACM Computing Surveys* 56 (2), S. 1–36.
- Barlaug, N. und Gulla, J. A. (2021): Neural Networks for Entity Matching: A Survey, *ACM Transactions on Knowledge Discovery from Data (TKDD)* 15 (3), S. 1–37.
- Druzhkina, A., Leontyev, A. und Stepanova, M. (2016): German NER with a Multilingual Rule Based Information Extraction System: Analysis and Issues. In: *Proceedings of the Sixth Named Entity Workshop*. S. 28–33.
- Fiebach, D. (2026): Ausgangssituation. Unveröffentlichtes Dokument, Spedifix Logistiksoftware GmbH & Co. KG, Version 1.0.0, 10. April 2026
- Gerards, A. M. H. (1995): Matching. In: Ball, M. O. et al. (Hrsg.): *Handbooks in Operations Research and Management Science*, Vol. 7. Elsevier Science B. V., S. 135–224.
- Hakak, S. I., Kamsin, A., Shivakumara, P., Gilkar, G. A., Khan, W. Z. und Imran, M. (2019): Exact String Matching Algorithms: Survey, Issues, and Future Research Directions, *IEEE Access* 7, S. 69614–69637.
- Hamad, K. und Kaya, M. (2016): A Detailed Analysis of Optical Character Recognition Technology, *International Journal of Applied Mathematics Electronics and Computers*, Special Issue-1, S. 244–249.
- Hou, B., Chen, Q., Chen, Z., Nafa, Y. und Li, Z. (2018): r-HUMO: A Risk-Aware Human-Machine Cooperation Framework for Entity Resolution with Quality Guarantees, *IEEE Transactions on Knowledge and Data Engineering* 32 (2), S. 347–359.
- Ingram, W. A., Wu, J., Kahu, S. Y., Manzoor, J. A., Banerjee, B., Ahuja, A., Choudhury, M. H., Salsabil, L., Shields, W. und Fox, E. A. (2024): Building Datasets to Support Information Extraction and Structure Parsing from Electronic Theses and Dissertations, *International Journal on Digital Libraries* 25 (2), S. 175–196.
- Jiang, J. (2012): Information Extraction from Text. In: *Mining Text Data*. Springer US, Boston, MA, S. 11–41.
- Kalluru, J. (2022). Enhancing data accuracy and efficiency: An overview of fuzzy matching techniques. *International Journal of Science and Research*, 12(8), 685–690.
- Karr, A. F., Taylor, M. T., West, S. L., Setoguchi, S., Kou, T. D., Gerhard, T. und Horton, D. B. (2019): Comparing Record Linkage Software Programs and Algorithms Using Real-World Data, *PLOS ONE* 14 (9), S. 1–16, Art. e0221459.
- Kaur, S., Mann, P. und Khurana, S. (2013): Page Segmentation in OCR System – A Review, *International Journal of Computer Science and Information Technologies* 4 (3), S. 420–422.

- Kim, G., Hong, T., Yim, M., Nam, J., Park, J., Yim, J., Hwang, W., Yun, S., Han, D. und Park, S. (2022): OCR-Free Document Understanding Transformer. arXiv:2111.15664v5. URL: <https://arxiv.org/abs/2111.15664v5>, Abruf 22.07.2026.
- Kluegl, P., Toepfer, M., Beck, P. D., Fette, G. und Puppe, F. (2016): UIMA Ruta: Rapid Development of Rule-Based Information Extraction Applications, *Natural Language Engineering* 22 (1), S. 1–40.
- Knuth, D. E., Morris, J. H. Jr. und Pratt, V. R. (1977): Fast Pattern Matching in Strings, *SIAM Journal on Computing* 6 (2), S. 323–350.
- Li, J., Sun, A., Han, J. und Li, C. (2020): A Survey on Deep Learning for Named Entity Recognition, *IEEE Transactions on Knowledge and Data Engineering* 34 (1), S. 50–70.
- Li, M., Lv, T., Chen, J., Cui, L., Lu, Y., Florencio, D., Zhang, C., Li, Z. und Wei, F. (2023): TrOCR: Transformer-Based Optical Character Recognition with Pre-trained Models. In: *Proceedings of the AAAI Conference on Artificial Intelligence* 37 (11), S. 13094–13102.
- Maciejewski, J., Nikoletos, K., Papadakis, G. und Velegrakis, Y. (2025): Progressive Entity Matching: A Design Space Exploration, *Proceedings of the ACM on Management of Data* 3 (1), Art. 65, S. 1–25.
- Mukherjee, S., Tyagi, H., Tyagi, P., Singh, N. und Bhardwaj, S. (2023): OCR Using Python and Its Application, *Journal of Advanced Zoology* 44 (S-3), S. 1083–1092.
- Papadakis, G., Efthymiou, V., Thanos, E., Hassanzadeh, O. und Christen, P. (2023): An Analysis of One-to-One Matching Algorithms for Entity Resolution, *The VLDB Journal* 32 (6), S. 1369–1400.
- Patel, C., Patel, A. und Patel, D. (2012): Optical Character Recognition by Open Source OCR Tool Tesseract: A Case Study, *International Journal of Computer Applications* 55 (10), S. 50–56.
- Rozinek, O., Marek, J., Panuš, J. und Mareš, J. (2025): Real-Time Fuzzy Record-Matching Similarity Metric and Optimal Q-Gram Filter, *Algorithms* 18 (3), S. 1–32, Art. 150.
- Wang, Y. (2024): Leveraging Large Language Models for Fuzzy String Matching in Political Science. arXiv preprint arXiv:2403.18218v1. URL: <https://arxiv.org/abs/2403.18218v1>, Abruf 24.07.2026.
- Principe, R. A., Viviani, M. und Chiarini, N. (2025): Enhancing Information Extraction with Large Language Models: A Comparison with Human Annotation and Rule-Based Methods in a Real Estate Case Study. In: Alam, M.; Tchechmedjiev, A.; Gracia, J.; Gromann, D.; di Buono, M. P.; Monti, J.; Ionov, M. (Hrsg.): *Proceedings of the 5th Conference on Language, Data and Knowledge*. Unior Press, Neapel, S. 243–254.

- Xu, D., Chen, W., Peng, W., Zhang, C., Xu, T., Zhao, X., Wu, X., Zheng, Y., Wang, Y. und Chen, E. (2024): Large Language Models for Generative Information Extraction: A Survey, *Frontiers of Computer Science* 18 (6), Art. 186357.
- Xu, Y., Li, M., Cui, L., Huang, S., Wei, F. und Zhou, M. (2020): LayoutLM: Pre-training of Text and Layout for Document Image Understanding. In: *Proceedings of the 26th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*. S. 1192–1200.
- Zong, C., Xia, R. und Zhang, J. (2021): Information Extraction. In: *Text Data Mining*. Springer, Singapore, S. 227–283.

**Eigenständigkeitserklärung für studienbegleitende schriftliche Prüfungen,
die ohne Aufsicht absolviert werden**

Erklärung von (Vorname Name, Matrikelnummer): Fajer Ahmed, 400855

über die selbstständige Erbringung der Prüfungsleistung:

Art der Prüfungsleistung (z.B. Hausarbeit): Schriftliche Ausarbeitung & Prototyp

in der Lehrveranstaltung (LSF-Nr. und Titel der Lehrveranstaltung): 3223, IT-Studienprojekt B. Sc. WI

Oder bei Prüfungen, die keiner Lehrveranstaltung zugeordnet sind (LSF-Prüfungsnummer und Angabe des Semesters):

Ich versichere hiermit, dass ich die vorstehende Prüfungsleistung selbstständig erbracht und keine anderen als die angegebenen Hilfsmittel benutzt habe.

Die Stellen der oben genannten Arbeit, die anderen Werken dem Wortlaut oder dem Sinn nach entnommen wurden, habe ich in jedem einzelnen Fall durch die Angabe der Quelle bzw. der Herkunft als Entlehnung kenntlich gemacht. Dies gilt auch für Zeichnungen, Skizzen, bildliche Darstellungen sowie für Quellen aus dem Internet und anderen elektronischen Text- und Datensammlungen und dergleichen.

Gemäß der von der bzw. dem Prüfenden getroffenen Entscheidung bezüglich einer Verwendung **von KI-Systemen** gebe ich die nachfolgend angekreuzte Versicherung ab.

(Zutreffendes bitte ankreuzen)

☐

1. Verbot der Verwendung von KI-Systemen

Ich versichere, dass ich zur Erstellung der vorliegenden Arbeit keine KI-Systeme genutzt habe.

☒

2. Erlaubnis der Verwendung von KI-Systemen mit Dokumentationspflicht

Ich bin mir bewusst, dass mit der Nutzung von KI-Systemen keine Garantie für die Qualität von Inhalten und Texten oder anderen Darstellungsformen verbunden ist. Ich verantworte die Übernahme jeglichen Outputs der von mir verwendeten KI-Systeme vollumfänglich selbst. Ich habe alle von der KI generierten Outputs als solche ausgewiesen.

In der Anlage „Dokumentation der Verwendung von KI-Systemen“ habe ich dargelegt, welche KI-Systeme ich genutzt habe, für welchen Zweck ich diese verwendet habe und auf welche Weise die Nutzung stattfand.

☐

3. Gebot der Nutzung von KI-Systemen mit Dokumentationspflicht

Ich versichere, dass ich die von der oder dem Erstprüfenden explizit vorgegebenen KI-Systeme genutzt und alle von der KI generierten Outputs als solche ausgewiesen habe.

In der Anlage „Dokumentation der Verwendung von KI-Systemen“ habe ich dargelegt, für welchen Zweck ich welche Systeme verwendet habe und auf welche Weise die Nutzung stattfand.

Ich bin mir bewusst, dass mit der Nutzung von KI-Systemen keine Garantie für die Qualität von Inhalten und Texten oder anderen Darstellungsformen verbunden ist.


Ich verantworte die Übernahme jeglichen Outputs der von mir verwendeten KI-Systeme vollumfänglich selbst.

Die eingereichte Arbeit ist nicht anderweitig als Prüfungsleistung verwendet worden oder in deutscher oder in einer anderen Sprache als Veröffentlichung erschienen.

Mir ist bewusst, dass wahrheitswidrige Angaben als Täuschung behandelt werden.

28.08.2026, Hannover

(Ort, Datum)



(Unterschrift)

**Anlage zur Eigenständigkeitserklärung zu meiner Prüfungsleistung:
Dokumentation der Verwendung von KI-Systemen**

In meiner Prüfungsleistung mit der LSF-Prüfungsnummer

bzw. zur Lehrveranstaltung

IT-Studienprojekt B.Sc. WI 3223

(Titel, LSF-Nr.)

habe ich die unten genannten KI-Systeme wie im Folgenden beschrieben eingesetzt.

Zweck der Verwendung	Eingesetzte(s) KI- System(e)	Beschreibung der Verwendungsweise
Generierung von Ideen und Konzeption der Arbeit		
Literatursuche		
Literaturanalyse		
Literaturverwaltung und Zitationsmanagement		
Auswahl von Methoden und Modellen		
Datensammlung und -analyse		
Generierung / Überprüfung von Programmcodes	ChatGPT	Überprüfung von Code, Validierung von Funktionalitäten, Fallback Untersuchung
Erstellung / Optimierung von Visualisierungen von Daten		
Erstellung bildlicher Darstellungen		
Interpretation und Validierung von Daten		
Strukturierung des Texts der Arbeit		

Zweck der Verwendung	Eingesetzte(s) KI- System(e)	Beschreibung der Verwendungsweise
Formulierung des Texts der Arbeit	ChatGPT	Überprüfung der Textformulierung, Suche nach Synonymen
Übersetzung		
Redigieren des Texts		
Layouten der Arbeit		
Plausibilitätsprüfung meiner Argumentation(en)		
Vorbereitung der Präsentation der Arbeit		
Sonstiges		

Hannover, 28.08.2026

(Ort, Datum)



(Unterschrift)

**Eigenständigkeitserklärung für studienbegleitende schriftliche Prüfungen,
die ohne Aufsicht absolviert werden**

Erklärung von (Vorname Name, Matrikelnummer): Ali Kemaliddin Artun, 400010

über die selbstständige Erbringung der Prüfungsleistung:

Art der Prüfungsleistung (z.B. Hausarbeit): Schriftliche Ausarbeitung und Prototyp IT-Studienprojekt

in der Lehrveranstaltung (LSF-Nr. und Titel der Lehrveranstaltung):
3223, IT-Studienprojekt B.Sc. WI

Oder bei Prüfungen, die keiner Lehrveranstaltung zugeordnet sind (LSF-Prüfungsnummer und Angabe des Semesters):

Ich versichere hiermit, dass ich die vorstehende Prüfungsleistung selbstständig erbracht und keine anderen als die angegebenen Hilfsmittel benutzt habe.

Die Stellen der oben genannten Arbeit, die anderen Werken dem Wortlaut oder dem Sinn nach entnommen wurden, habe ich in jedem einzelnen Fall durch die Angabe der Quelle bzw. der Herkunft als Entlehnung kenntlich gemacht. Dies gilt auch für Zeichnungen, Skizzen, bildliche Darstellungen sowie für Quellen aus dem Internet und anderen elektronischen Text- und Datensammlungen und dergleichen.

Gemäß der von der bzw. dem Prüfenden getroffenen Entscheidung bezüglich einer Verwendung **von KI-Systemen** gebe ich die nachfolgend angekreuzte Versicherung ab.

(Zutreffendes bitte ankreuzen)

☐

1. Verbot der Verwendung von KI-Systemen

Ich versichere, dass ich zur Erstellung der vorliegenden Arbeit keine KI-Systeme genutzt habe.

☒

2. Erlaubnis der Verwendung von KI-Systemen mit Dokumentationspflicht

Ich bin mir bewusst, dass mit der Nutzung von KI-Systemen keine Garantie für die Qualität von Inhalten und Texten oder anderen Darstellungsformen verbunden ist. Ich verantworte die Übernahme jeglichen Outputs der von mir verwendeten KI-Systeme vollumfänglich selbst. Ich habe alle von der KI generierten Outputs als solche ausgewiesen.

In der Anlage „Dokumentation der Verwendung von KI-Systemen“ habe ich dargelegt, welche KI-Systeme ich genutzt habe, für welchen Zweck ich diese verwendet habe und auf welche Weise die Nutzung stattfand.

☐

3. Gebot der Nutzung von KI-Systemen mit Dokumentationspflicht

Ich versichere, dass ich die von der oder dem Erstprüfenden explizit vorgegebenen KI-Systeme genutzt und alle von der KI generierten Outputs als solche ausgewiesen habe.

In der Anlage „Dokumentation der Verwendung von KI-Systemen“ habe ich dargelegt, für welchen Zweck ich welche Systeme verwendet habe und auf welche Weise die Nutzung stattfand.

Ich bin mir bewusst, dass mit der Nutzung von KI-Systemen keine Garantie für die Qualität von Inhalten und Texten oder anderen Darstellungsformen verbunden ist.

Ich verantworte die Übernahme jeglichen Outputs der von mir verwendeten KI-Systeme vollumfänglich selbst.

Die eingereichte Arbeit ist nicht anderweitig als Prüfungsleistung verwendet worden oder in deutscher oder in einer anderen Sprache als Veröffentlichung erschienen.

Mir ist bewusst, dass wahrheitswidrige Angaben als Täuschung behandelt werden.

Hannover, 28.08.2026

A.K. Artun

(Ort, Datum)

(Unterschrift)

**Anlage zur Eigenständigkeitserklärung zu meiner Prüfungsleistung:
Dokumentation der Verwendung von KI-Systemen**

In meiner Prüfungsleistung mit der LSF-Prüfungsnummer 3223

bzw. zur Lehrveranstaltung

IT-Studienprojekt B.Sc. WI

(Titel, LSF-Nr.)

habe ich die unten genannten KI-Systeme wie im Folgenden beschrieben eingesetzt.

Zweck der Verwendung	Eingesetzte(s) KI- System(e)	Beschreibung der Verwendungsweise
Generierung von Ideen und Konzeption der Arbeit		
Literatursuche		
Literaturanalyse		
Literaturverwaltung und Zitationsmanagement		
Auswahl von Methoden und Modellen		
Datensammlung und -analyse		
Generierung / Überprüfung von Programmcodes	ChatGPT	Überprüfung von Code
Erstellung / Optimierung von Visualisierungen von Daten		
Erstellung bildlicher Darstellungen		
Interpretation und Validierung von Daten		
Strukturierung des Texts der Arbeit		

Zweck der Verwendung	Eingesetzte(s) KI- System(e)	Beschreibung der Verwendungsweise
Formulierung des Texts der Arbeit	ChatGPT	Überprüfung der Formulierung des Texts
Übersetzung		
Redigieren des Texts		
Layouten der Arbeit		
Plausibilitätsprüfung meiner Argumentation(en)		
Vorbereitung der Präsentation der Arbeit		
Sonstiges		

Hannover, 28.08.2026

(Ort, Datum)

A.K. Artn

(Unterschrift)

**Eigenständigkeitserklärung für studienbegleitende schriftliche Prüfungen,
die ohne Aufsicht absolviert werden**

Erklärung von (Vorname Name, Matrikelnummer): Matteo Geiger, 405375

über die selbstständige Erbringung der Prüfungsleistung:

Art der Prüfungsleistung (z.B. Hausarbeit): Schriftliche Ausarbeitung & Prototyp

in der Lehrveranstaltung (LSF-Nr. und Titel der Lehrveranstaltung):
3223, IT-Studienprojekt B.Sc. WI

Oder bei Prüfungen, die keiner Lehrveranstaltung zugeordnet sind (LSF-Prüfungsnummer und Angabe des Semesters):

Ich versichere hiermit, dass ich die vorstehende Prüfungsleistung selbstständig erbracht und keine anderen als die angegebenen Hilfsmittel benutzt habe.

Die Stellen der oben genannten Arbeit, die anderen Werken dem Wortlaut oder dem Sinn nach entnommen wurden, habe ich in jedem einzelnen Fall durch die Angabe der Quelle bzw. der Herkunft als Entlehnung kenntlich gemacht. Dies gilt auch für Zeichnungen, Skizzen, bildliche Darstellungen sowie für Quellen aus dem Internet und anderen elektronischen Text- und Datensammlungen und dergleichen.

Gemäß der von der bzw. dem Prüfenden getroffenen Entscheidung bezüglich einer Verwendung **von KI-Systemen** gebe ich die nachfolgend angekreuzte Versicherung ab.

(Zutreffendes bitte ankreuzen)

☐

1. Verbot der Verwendung von KI-Systemen

Ich versichere, dass ich zur Erstellung der vorliegenden Arbeit keine KI-Systeme genutzt habe.

☒

2. Erlaubnis der Verwendung von KI-Systemen mit Dokumentationspflicht

Ich bin mir bewusst, dass mit der Nutzung von KI-Systemen keine Garantie für die Qualität von Inhalten und Texten oder anderen Darstellungsformen verbunden ist. Ich verantworte die Übernahme jeglichen Outputs der von mir verwendeten KI-Systeme vollumfänglich selbst. Ich habe alle von der KI generierten Outputs als solche ausgewiesen.

In der Anlage „Dokumentation der Verwendung von KI-Systemen“ habe ich dargelegt, welche KI-Systeme ich genutzt habe, für welchen Zweck ich diese verwendet habe und auf welche Weise die Nutzung stattfand.

☐

3. Gebot der Nutzung von KI-Systemen mit Dokumentationspflicht

Ich versichere, dass ich die von der oder dem Erstprüfenden explizit vorgegebenen KI-Systeme genutzt und alle von der KI generierten Outputs als solche ausgewiesen habe.

In der Anlage „Dokumentation der Verwendung von KI-Systemen“ habe ich dargelegt, für welchen Zweck ich welche Systeme verwendet habe und auf welche Weise die Nutzung stattfand.

Ich bin mir bewusst, dass mit der Nutzung von KI-Systemen keine Garantie für die Qualität von Inhalten und Texten oder anderen Darstellungsformen verbunden ist.

Ich verantworte die Übernahme jeglichen Outputs der von mir verwendeten KI-Systeme vollumfänglich selbst.

Die eingereichte Arbeit ist nicht anderweitig als Prüfungsleistung verwendet worden oder in deutscher oder in einer anderen Sprache als Veröffentlichung erschienen.

Mir ist bewusst, dass wahrheitswidrige Angaben als Täuschung behandelt werden.

(Ort, Datum)

Hildesheim
28.08.2026

(Unterschrift)

Matteo Geiger

**Anlage zur Eigenständigkeitserklärung zu meiner Prüfungsleistung:
Dokumentation der Verwendung von KI-Systemen**

In meiner Prüfungsleistung mit der LSF-Prüfungsnummer 3223
IT-Studienprojekt B.Sc. WI

bzw. zur Lehrveranstaltung

(Titel, LSF-Nr.)

habe ich die unten genannten KI-Systeme wie im Folgenden beschrieben eingesetzt.

Zweck der Verwendung	Eingesetzte(s) KI- System(e)	Beschreibung der Verwendungsweise
Generierung von Ideen und Konzeption der Arbeit		
Literatursuche		
Literaturanalyse		
Literaturverwaltung und Zitationsmanagement		
Auswahl von Methoden und Modellen		
Datensammlung und -analyse		
Generierung / Überprüfung von Programmcodes	Claude	Claude wurde teilweise unterstützend bei der Konzeption und Umsetzung der Benutzeroberfläche eingesetzt.
Erstellung / Optimierung von Visualisierungen von Daten		
Erstellung bildlicher Darstellungen		
Interpretation und Validierung von Daten		
Strukturierung des Texts der Arbeit		

Zweck der Verwendung	Eingesetzte(s) KI- System(e)	Beschreibung der Verwendungsweise
Formulierung des Texts der Arbeit		
Übersetzung		
Redigieren des Texts	Claude	Eine Rechtschreib und Grammatiküberprüfung vor der eigenen.
Layouten der Arbeit		
Plausibilitätsprüfung meiner Argumentation(en)		
Vorbereitung der Präsentation der Arbeit		
Sonstiges		

(Ort, Datum)

Hildesheim
28.08.2026

(Unterschrift)

Matthias Carsten

**Eigenständigkeitserklärung für studienbegleitende schriftliche Prüfungen,
die ohne Aufsicht absolviert werden**

Erklärung von (Vorname Name, Matrikelnummer): Tim Wiedenroth, 402240

über die selbstständige Erbringung der Prüfungsleistung:

Art der Prüfungsleistung (z.B. Hausarbeit): Schriftliche Ausarbeitung und Prototyp Entwicklung

in der Lehrveranstaltung (LSF-Nr. und Titel der Lehrveranstaltung):
3223 IT-Studienprojekt Bachelor

Oder bei Prüfungen, die keiner Lehrveranstaltung zugeordnet sind (LSF-Prüfungsnummer und Angabe des Semesters):

Ich versichere hiermit, dass ich die vorstehende Prüfungsleistung selbstständig erbracht und keine anderen als die angegebenen Hilfsmittel benutzt habe.

Die Stellen der oben genannten Arbeit, die anderen Werken dem Wortlaut oder dem Sinn nach entnommen wurden, habe ich in jedem einzelnen Fall durch die Angabe der Quelle bzw. der Herkunft als Entlehnung kenntlich gemacht. Dies gilt auch für Zeichnungen, Skizzen, bildliche Darstellungen sowie für Quellen aus dem Internet und anderen elektronischen Text- und Datensammlungen und dergleichen.

Gemäß der von der bzw. dem Prüfenden getroffenen Entscheidung bezüglich einer Verwendung **von KI-Systemen** gebe ich die nachfolgend angekreuzte Versicherung ab.

(Zutreffendes bitte ankreuzen)

☐

1. Verbot der Verwendung von KI-Systemen

Ich versichere, dass ich zur Erstellung der vorliegenden Arbeit keine KI-Systeme genutzt habe.

☒

2. Erlaubnis der Verwendung von KI-Systemen mit Dokumentationspflicht

Ich bin mir bewusst, dass mit der Nutzung von KI-Systemen keine Garantie für die Qualität von Inhalten und Texten oder anderen Darstellungsformen verbunden ist. Ich verantworte die Übernahme jeglichen Outputs der von mir verwendeten KI-Systeme vollumfänglich selbst. Ich habe alle von der KI generierten Outputs als solche ausgewiesen.

In der Anlage „Dokumentation der Verwendung von KI-Systemen“ habe ich dargelegt, welche KI-Systeme ich genutzt habe, für welchen Zweck ich diese verwendet habe und auf welche Weise die Nutzung stattfand.

☐

3. Gebot der Nutzung von KI-Systemen mit Dokumentationspflicht

Ich versichere, dass ich die von der oder dem Erstprüfenden explizit vorgegebenen KI-Systeme genutzt und alle von der KI generierten Outputs als solche ausgewiesen habe.

In der Anlage „Dokumentation der Verwendung von KI-Systemen“ habe ich dargelegt, für welchen Zweck ich welche Systeme verwendet habe und auf welche Weise die Nutzung stattfand.

Ich bin mir bewusst, dass mit der Nutzung von KI-Systemen keine Garantie für die Qualität von Inhalten und Texten oder anderen Darstellungsformen verbunden ist.

Ich verantworte die Übernahme jeglichen Outputs der von mir verwendeten KI-Systeme vollumfänglich selbst.

Die eingereichte Arbeit ist nicht anderweitig als Prüfungsleistung verwendet worden oder in deutscher oder in einer anderen Sprache als Veröffentlichung erschienen.

Mir ist bewusst, dass wahrheitswidrige Angaben als Täuschung behandelt werden.

28.08.2026

(Ort, Datum)


(Unterschrift)

**Anlage zur Eigenständigkeitserklärung zu meiner Prüfungsleistung:
Dokumentation der Verwendung von KI-Systemen**

In meiner Prüfungsleistung mit der LSF-Prüfungsnummer 3223
3223 IT-Studienprojekt Bachelor

bzw. zur Lehrveranstaltung

(Titel, LSF-Nr.)

habe ich die unten genannten KI-Systeme wie im Folgenden beschrieben eingesetzt.

Zweck der Verwendung	Eingesetzte(s) KI- System(e)	Beschreibung der Verwendungsweise
Generierung von Ideen und Konzeption der Arbeit		
Literatursuche		
Literaturanalyse		
Literaturverwaltung und Zitationsmanagement		
Auswahl von Methoden und Modellen		
Datensammlung und -analyse		
Generierung / Überprüfung von Programmcodes	Cursor	Überprüfung des Programmcodes
Erstellung / Optimierung von Visualisierungen von Daten		
Erstellung bildlicher Darstellungen		
Interpretation und Validierung von Daten		
Strukturierung des Texts der Arbeit	Claude (Anthropic)	Überprüfung der Struktur des Textes

Zweck der Verwendung	Eingesetzte(s) KI- System(e)	Beschreibung der Verwendungsweise
Formulierung des Texts der Arbeit	Claude (Anthropic)	Überprüfung einzelner Textpassagen
Übersetzung		
Redigieren des Texts		
Layouten der Arbeit		
Plausibilitätsprüfung meiner Argumentation(en)		
Vorbereitung der Präsentation der Arbeit		
Sonstiges		

28.08.2026

(Ort, Datum)

T. Wieden

(Unterschrift)